Tarea2_Martel_Vásquez

June 2, 2025

```
c:\Users\jano7\AppData\Local\Programs\Python\Python312\Lib\site-
packages\tqdm\auto.py:21: TqdmWarning: IProgress not found. Please update
jupyter and ipywidgets. See
https://ipywidgets.readthedocs.io/en/stable/user_install.html
  from .autonotebook import tqdm as notebook_tqdm
```

Los resultados de los ejericicios propuestos se deben entregar como un notebook por correo electronico a juancaros@udec.cl el dia 20/5 hasta las 21:00. Es importante considerar que el código debe poder ejecutarse en cualquier computadora con la data original del repositorio. Recordar la convencion para el nombre de archivo ademas de incluir en su documento titulos y encabezados por seccion.

El archivo a utilizar es panel_eps.csv, que contiene un resumen de la Encuesta de Proteccion Social, en particular la caracterizacion de los individuos en distintas rondas, su situacion laboral y de salud.

0.1 Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadisticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.

R. Al analizar la base de datos se procedio con las siguientes modificaciones: 1. Se eliminó las columnas ‘fondoa’,‘fondob’,‘fondoc’,‘fondod’,‘fondoe’, ya que poseian en su totalidad datos nulos. 2. Se verifico que el panel tuviera las rondas constantes a los tiempos, lo cual identifico que la ronda 1 ocurrio en 2002, la 2 en 2004, la 3 en 2006, 4 en 2009, 5 en 2012, 6 en 2015. 3. Se verifico que el sexo no cambiara con el paso de los periodos de estudio. 4. Se realizo una modificacion de la variable ‘edad’, ya que poseia valores en formato “años” y otras en formato “fecha de nacimiento”, asimismo los datos con el segundo formato poseian un error, lo cual la edad de nacimiento iba cambiando con el tiempo, para corregirlo, por Id se modifico el año la primera vez que aparecia y se reemplazaba en los demás periodos, luego se calculo la edad restando este con el periodo. 5. Se identidico que en la primera ronda no existian valores realacionados a enfermedades, por ello se imputaron los valores con el Metodo MICE, luego se aproximaron los valores obtenidos para obtener valores binarias. Además se agrego una variable indicadora con 0 si se inputo o 1 si no se inputo. 6. Se eliminaron los valores nulos de expectancy, ya que al ser la variable dependiente, necesitamos de data se necesita ajustar a algo. 7. Se agrupo los valores de la columna situation a 0 si no trabajaba y 1 si trabajaba, además se reemplazaron los valores nulos de hours y wage, por 0 si es que no trabajaba. 8. Se transformaron a variables dummy “status” y “lmp”. Al ser variables categoricas se necesitan tratar con este metodo, para evitar falsas relaciones, se transformo además valores (True y False) a 0 y 1. 9. Se reemplazaron los valores de “publicemp”, “selfemp” e “informal” por 0 si es que la persona no trabajaba. 10. Se imputaron además las variables ‘region’, ‘children’, ‘exp’, ‘wage’, ‘hours’, ‘assets’, ‘sistema’, ‘cotizando’, se agrego una variable indicadora

con 0 si se inputo o 1 si no se inputo. Se hizo una transformacion logaritmica de las variables wage y assets, los assets faltantes se agregaron con 0, se aproximo la cantidad imputada de niños con el entero superior, y sistema se aproximo con el entero más cercano, 11. Se reemplazaron valores nulos cuando la situacion era cesante y desempleado en las variables "publicemp", "selfemp", "informal", al no trabajar, no pertenece en ese periodo a estos grupos. 12. Analiamos el comportamiento de los datos limpios. 13. Se opta por eliminar las variables "size", "occupation" y region, poseen gran cantidad de valores nulos especialmente cuando la persona no trabaja. Por ello para tener más data para realizar los modelos se elimino estas variables. 14. Se eliminan los datos nulos restantes. 15. Se Observa en los graficos boxplot una gran cantidad de outliders de las variables wage y assets y unos pocos en children, se eliminan mediante el rango intercuartil. 16. Finalmente se crea una nueva variable para agregar el peso de la persona por permanecer en la encuesta.

Se realizo el trabajo anteriormente imputando edu, con 60k de filas, pero resulto en un mal modelo, por ello se trabajo con menos filas pero datos reales.

```
           folio_n20  year  time  edad  hombre   edu  region  status  kids  \
0       124560204870     4     2    49     0.0   7.0     5.0     3.0     1
1       124560204870     6     3    51     0.0   4.0     5.0     3.0     1
2       124560204870     9     4    54     0.0   5.0     5.0     3.0     1
3       124560204870    12     5    57     0.0   4.0     NaN     5.0     0
4       124560205935     2     1  1982     0.0  15.0    13.0     3.0     1
…                  …   …   …   …      …   …      …     …   …
96841   128133653188    12     5  1992     0.0  16.0     NaN     3.0     0
96842   128133692735    12     5  1992     0.0  12.0     NaN     2.0     0
96843   128133702320    12     5  1992     0.0  15.0     NaN     5.0     0
96844   128133728022    12     5  1992     0.0   8.0     NaN     2.0     0
96845   128133731927    12     5  1992     1.0   8.0     NaN     2.0     0

        children  …  fondob  fondoc  fondod  fondoe  exp_sist  expectancy  \
0            1.0  …     NaN     NaN     NaN     NaN         0        58.0
1            1.0  …     NaN     NaN     NaN     NaN         0        55.0
2            1.0  …     NaN     NaN     NaN     NaN         0        70.0
3            0.0  …     NaN     NaN     NaN     NaN         0        70.0
4            4.0  …     NaN     NaN     NaN     NaN        19        75.0
…          …  …     …     …     …     …     …     …
96841        0.0  …     NaN     NaN     NaN     NaN         7        80.0
96842        0.0  …     NaN     NaN     NaN     NaN         7        80.0
96843        0.0  …     NaN     NaN     NaN     NaN         7        75.0
96844        0.0  …     NaN     NaN     NaN     NaN         6        70.0
96845        0.0  …     NaN     NaN     NaN     NaN         7        90.0

        illness  cronica  nocronica  mental
0           1.0      0.0        1.0     0.0
1           0.0      0.0        0.0     0.0
2           1.0      0.0        0.0     1.0
3           1.0      0.0        0.0     0.0
4           NaN      NaN        NaN     NaN
…         …      …        …     …
```

```
96841      0.0      0.0        0.0     0.0
96842      1.0      0.0        0.0     0.0
96843      0.0      0.0        0.0     0.0
96844      1.0      0.0        0.0     0.0
96845      0.0      0.0        0.0     0.0

[96846 rows x 34 columns]

folio_n20         0
year              0
time              0
edad              0
hombre           50
edu            3926
region        15998
status          110
kids              0
children      18829
situation         0
lmp               0
exp           11977
size          67802
occupation    47069
wage          42949
hours         42270
informal      55587
selfemp       41344
publicemp     41344
sistema       20643
cotizando      4808
assets        16087
fondoa        96846
fondob        96846
fondoc        96846
fondod        96846
fondoe        96846
exp_sist          0
expectancy    26565
illness       16438
cronica       16309
nocronica     16309
mental        16309
dtype: int64

¿Se cumple la condición en todos los casos? True
¿Todos los IDs mantienen el mismo sexo? True
```

	folio_n20	year	time	edad	hombre	\
count	7.028100e+04	70281.000000	70281.000000	70281.000000	70255.000000	
mean	1.254262e+11	6.359855	2.898052	1697.426388	0.506270	
std	1.370468e+09	3.558016	1.426039	683.463969	0.499964	
min	1.245602e+11	2.000000	1.000000	20.000000	0.000000	
25%	1.246215e+11	4.000000	2.000000	1982.000000	0.000000	
50%	1.247951e+11	6.000000	3.000000	1982.000000	1.000000	
75%	1.248514e+11	9.000000	4.000000	1983.000000	1.000000	
max	1.281337e+11	12.000000	5.000000	1993.000000	1.000000	

	edu	region	kids	children	situation	\
count	69236.000000	57671.000000	70281.000000	70281.000000	70281.000000	
mean	8.070195	9.117893	0.412814	0.866237	0.608116	
std	5.126863	3.670482	0.492343	1.002370	0.488174	
min	0.000000	1.000000	0.000000	0.000000	0.000000	
25%	4.000000	6.000000	0.000000	0.000000	0.000000	
50%	8.000000	9.000000	0.000000	1.000000	1.000000	
75%	12.000000	13.000000	1.000000	1.000000	1.000000	
max	19.000000	15.000000	1.000000	8.000000	1.000000	

	…	status_5.0	lmp_1	lmp_2	children_flag	\
count	…	70281.000000	70281.000000	70281.000000	70281.000000	
mean	…	0.269703	0.035714	0.569969	0.873494	
std	…	0.443809	0.185577	0.495084	0.332422	
min	…	0.000000	0.000000	0.000000	0.000000	
25%	…	0.000000	0.000000	0.000000	1.000000	
50%	…	0.000000	0.000000	1.000000	1.000000	
75%	…	1.000000	0.000000	1.000000	1.000000	
max	…	1.000000	1.000000	1.000000	1.000000	

	exp_flag	wage_flag	hours_flag	assets_flag	sistema_flag	\
count	70281.000000	70281.000000	70281.000000	70281.000000	70281.000000	
mean	0.908880	0.973464	0.986341	0.819340	0.817276	
std	0.287782	0.160725	0.116074	0.384739	0.386443	
min	0.000000	0.000000	0.000000	0.000000	0.000000	
25%	1.000000	1.000000	1.000000	1.000000	1.000000	
50%	1.000000	1.000000	1.000000	1.000000	1.000000	
75%	1.000000	1.000000	1.000000	1.000000	1.000000	
max	1.000000	1.000000	1.000000	1.000000	1.000000	

	cotizando_flag
count	70281.000000
mean	0.956204
std	0.204642
min	0.000000
25%	1.000000
50%	1.000000

```
75%          1.000000
max          1.000000

[8 rows x 45 columns]

      folio_n20  year  time  edad  hombre   edu  region  kids  children  \
0  124560204870     4     2    49     0.0   7.0     5.0     1       1.0
1  124560204870     6     3    51     0.0   4.0     5.0     1       1.0
2  124560204870     9     4    54     0.0   5.0     5.0     1       1.0
3  124560204870    12     5    57     0.0   4.0     NaN     0       0.0
4  124560205935     2     1  1982     0.0  15.0    13.0     1       4.0

   situation  …  status_5.0  lmp_1  lmp_2  children_flag  exp_flag  \
0          0  …           0      0      0              1         0
1          0  …           0      0      0              1         0
2          0  …           0      0      0              1         0
3          1  …           1      1      0              1         0
4          0  …           0      0      0              1         1

   wage_flag  hours_flag  assets_flag  sistema_flag  cotizando_flag
0          1           1            1             0               1
1          1           1            1             1               1
2          1           1            1             1               1
3          1           1            0             1               1
4          1           1            1             1               1

[5 rows x 45 columns]

folio_n20         0
year              0
time              0
hombre            0
edu               0
kids              0
children          0
situation         0
exp               0
wage              0
hours             0
informal          0
selfemp           0
publicemp         0
sistema           0
cotizando         0
assets            0
exp_sist          0
expectancy        0
illness           0
```

```
cronica           0
nocronica         0
mental            0
nueva_edad        0
illness_flag      0
cronica_flag      0
nocronica_flag    0
mental_flag       0
status_2.0        0
status_3.0        0
status_4.0        0
status_5.0        0
lmp_1             0
lmp_2             0
children_flag     0
exp_flag          0
wage_flag         0
hours_flag        0
assets_flag       0
sistema_flag      0
cotizando_flag    0
dtype: int64
```

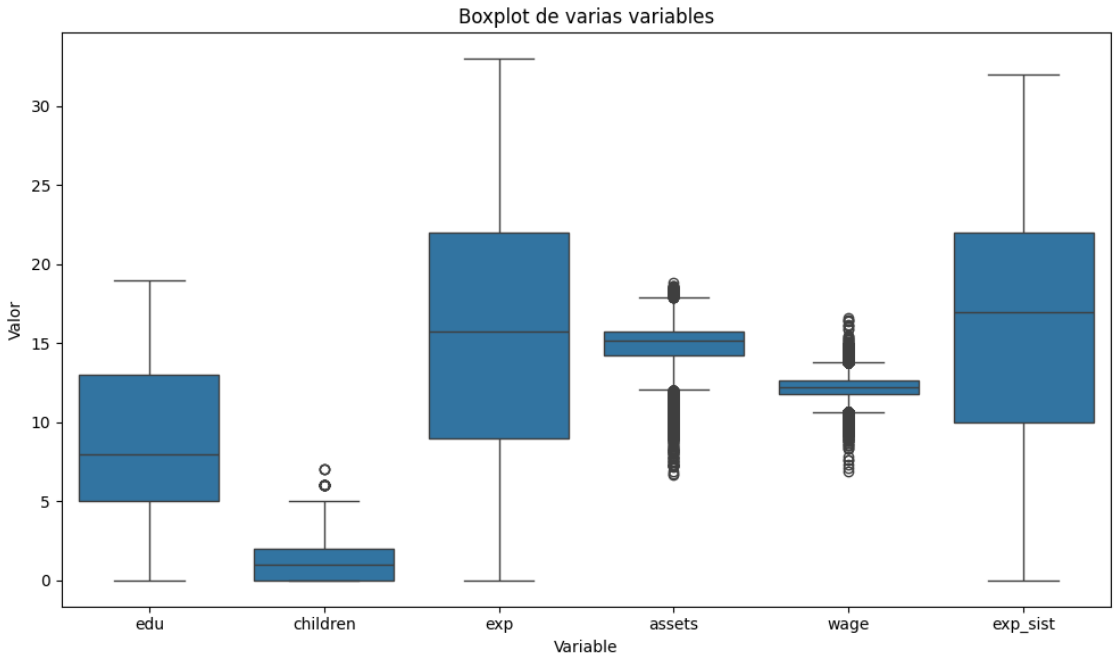

0.2 Ejecute un modelo Pooled OLS para estimar la relacion entre los anios de educacion y la expectativa de vida. Seleccione las variables independientes a incluir en el modelo final e interprete su significado

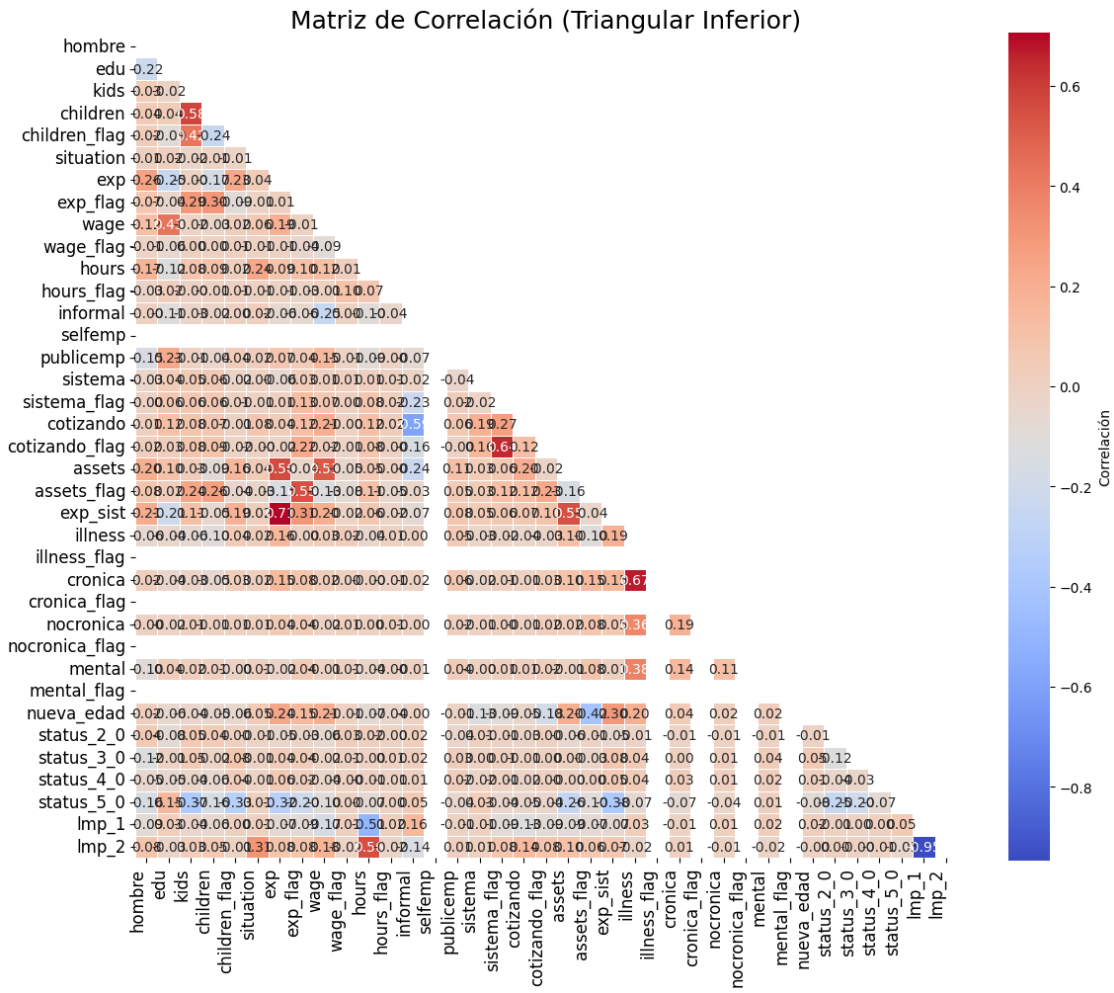


```
                            OLS Regression Results
==============================================================================
Dep. Variable:              expectancy   R-squared:                       0.146
Model:                             OLS   Adj. R-squared:                  0.145
Method:                  Least Squares   F-statistic:                     151.6
Date:                 Tue, 20 May 2025   Prob (F-statistic):               0.00
Time:                         20:53:17   Log-Likelihood:            -1.7468e+05
No. Observations:                26660   AIC:                         3.494e+05
Df Residuals:                    26629   BIC:                         3.497e+05
Df Model:                           30
Covariance Type:            nonrobust
================================================================================
==
```

```
                     coef    std err          t      P>|t|      [0.025
0.975]
------------------------------------------------------------------------------
--
hombre             0.0753      2.448      0.031      0.975      -4.724
4.874
time              55.8855      1.578     35.406      0.000      52.792
58.979
edu               -0.8164      0.276     -2.959      0.003      -1.357
-0.276
children           2.2525      1.737      1.297      0.195      -1.151
5.657
status_2_0        -1.1795      3.385     -0.348      0.728      -7.815
5.456
status_3_0         2.2551      3.942      0.572      0.567      -5.471
9.982
status_4_0        12.6322      9.684      1.304      0.192      -6.350
31.614
status_5_0         4.5256      2.949      1.535      0.125      -1.255
10.306
lmp_1            -36.0385     20.288     -1.776      0.076     -75.803
3.726
lmp_2            -35.4329     20.043     -1.768      0.077     -74.718
3.853
nocronica         -1.5613      7.731     -0.202      0.840     -16.714
13.592
mental           -28.5403      7.532     -3.789      0.000     -43.303
-13.777
nueva_edad         3.2205      0.500      6.443      0.000       2.241
4.200
illness_flag    -133.5379     38.414     -3.476      0.001    -208.832
-58.244
illness           -9.7757      4.889     -2.000      0.046     -19.358
-0.193
cronica           -4.6968      5.905     -0.795      0.426     -16.270
6.877
cotizando_flag     3.5401     11.679      0.303      0.762     -19.351
26.431
cotizando          3.6164      3.936      0.919      0.358      -4.097
11.330
assets_flag      218.4490      4.436     49.240      0.000     209.753
227.145
assets             1.2989      1.206      1.077      0.281      -1.065
3.662
sistema           -8.6025     12.157     -0.708      0.479     -32.430
15.225
sistema_flag      13.0907      8.745      1.497      0.134      -4.050
30.231
```

```
publicemp          0.2472      3.211      0.077      0.939      -6.047
6.541
informal           3.0179      4.220      0.715      0.475      -5.253
11.289
hours_flag      -147.8520     10.832    -13.649      0.000    -169.084
-126.621
hours              0.0792      0.126      0.630      0.529      -0.167
0.326
wage              -0.4067      2.479     -0.164      0.870      -5.266
4.452
exp                0.5150      0.184      2.800      0.005       0.154
0.875
exp_flag         -19.7350      6.248     -3.159      0.002     -31.981
-7.489
children_flag     16.0524      4.558      3.522      0.000       7.119
24.986
kids              -9.9068      3.788     -2.615      0.009     -17.331
-2.482
==============================================================================
Omnibus:                    19367.504   Durbin-Watson:                   2.025
Prob(Omnibus):                  0.000   Jarque-Bera (JB):           257775.848
Skew:                           3.521   Prob(JB):                         0.00
Kurtosis:                      16.508   Cond. No.                     2.39e+03
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
[2] The condition number is large, 2.39e+03. This might indicate that there are
strong multicollinearity or other numerical problems.
```

R. Para desarrolar el modelo, primero se eliminaron variables conflictivas, estas fueron: selfemp, exp_sist y situation. Viendo el analisis del PooledOLS, observamos un R^2 de 0,146 lo cual solo un 15% de la variabilidad de la expectativa de vida pueden ser explicados, lo cual es bajo. Viendo las variables, podemos observar que son significativas time, con un coeficiente de 56, indica que a mayor periodo la muestra encuestada tiende a tener mayores espectativas de vida, posiblemente por el avance de la medicina/tecnologia; mental de la misma manera indica que si tiene alguna enfermedad mental tiende a tener una expectativa de 28 años menos. La variable edu, que era la interesante en este modelo resulto ser significativa, con una influencia pequeña de que a mayor cantidad de años de estudio menor esperanza de vida. Otra variable es edad, la cual mientras mayor sea aumenta la expectativa de vida 3 años. Illness indica que si esta enfermo tiene menor expectativa de vida en 9 años. En general las variables flag que fueron significativas indican que si el dato es imputado la expectativa de vida es casi nula. Este modelo guia a un analisis detallado del comportamiento de los individuos muestreados, pero al considerar una muestra transversal simple sera mejor realizar otros modelos.

0.3 Ejecute un modelo efectos fijos para estimar la misma relacion anterior. Seleccione las variables independientes a incluir en el modelo final e interprete su significado.

Se transforman las variables_flag para marcar la interaccion entre su variable y el indicador. Se elimino la variable hombre, ya que era continua.

```
                          PanelOLS Estimation Summary
================================================================================
Dep. Variable:             expectancy   R-squared:                        0.1964
Estimator:                   PanelOLS   R-squared (Between):             -1.6890
No. Observations:               26660   R-squared (Within):               0.1964
Date:                Tue, May 20 2025   R-squared (Overall):             -0.7629
Time:                        20:53:18   Log-likelihood                -1.622e+05
Cov. Estimator:            Unadjusted
                                        F-statistic:                      165.19
Entities:                       12584   P-value                           0.0000
Avg Obs:                        2.1186   Distribution:                F(28,14048)
Min Obs:                        1.0000
Max Obs:                        5.0000   F-statistic (robust):             122.61
                                         P-value                           0.0000
Time periods:                        5   Distribution:                F(28,14048)
Avg Obs:                        5332.0
Min Obs:                        4438.0
Max Obs:                        7010.0

                                Parameter Estimates
================================================================================
==
                Parameter  Std. Err.     T-stat    P-value    Lower CI    Upper
CI
--------------------------------------------------------------------------------
--
edu                0.0036     0.7571     0.0048     0.9962     -1.4804
1.4877
children          -0.2692     10.719    -0.0251     0.9800     -21.280
20.742
status_2_0        -1.9678     7.7186    -0.2549     0.7988     -17.097
13.162
status_3_0         6.0323     8.2744     0.7290     0.4660     -10.187
22.251
status_4_0         11.808     23.326     0.5062     0.6127     -33.914
57.531
status_5_0         14.468     7.6642     1.8877     0.0591     -0.5550
29.491
lmp_1             -52.371     32.506    -1.6111     0.1072     -116.09
11.346
lmp_2             -37.729     31.665    -1.1915     0.2335     -99.796
```

```
24.339
nocronica         -2.4626     11.309    -0.2178     0.8276     -24.630
19.705
mental            -29.285     10.996    -2.6632     0.0077     -50.839
-7.7309
nueva_edad         43.138     1.7568     24.555     0.0000      39.694
46.581
illness_flag      -486.10     75.853    -6.4084     0.0000     -634.78
-337.42
illness           -15.558     8.0832    -1.9248     0.0543     -31.402
0.2859
cronica           -13.681     8.8957    -1.5379     0.1241     -31.117
3.7563
cotizando_flag    -82.917     34.862    -2.3784     0.0174     -151.25
-14.582
cotizando          92.053     34.522     2.6665     0.0077      24.386
159.72
assets_flag        18.136     0.4039     44.900     0.0000      17.344
18.928
assets            -26.834     2.7718    -9.6810     0.0000     -32.267
-21.401
sistema           -49.202     26.730    -1.8407     0.0657     -101.60
3.1931
sistema_flag       35.429     13.744     2.5777     0.0100      8.4884
62.370
publicemp          4.1140     7.2370     0.5685     0.5697     -10.071
18.299
informal           7.4617     7.3032     1.0217     0.3069     -6.8535
21.777
hours_flag        -3.7902     0.3657    -10.365     0.0000     -4.5069
-3.0734
hours              4.2675     0.4365     9.7771     0.0000      3.4120
5.1231
wage              -3.6598     5.1918    -0.7049     0.4809     -13.837
6.5169
exp                1.6313     11.308     0.1443     0.8853     -20.535
23.797
exp_flag          -12.537     11.285    -1.1110     0.2666     -34.656
9.5823
children_flag      1.3441     11.306     0.1189     0.9054     -20.818
23.506
kids              -4.2214     8.0794    -0.5225     0.6013     -20.058
11.615
==============================================================================
==

F-test for Poolability: 1.4728
P-value: 0.0000
```

```
Distribution: F(12583,14048)

Included effects: Entity
```

R. El modelo de efectos fijo nos indica que el 19% de la variabilidad de la expectativa de vida es explicada con el modelo, lo cual es mejor que el modelo anterior, tenemos de variables significativas edad, la cual a mayor edad, se espera que la expectativa de vida sea mayor, assets nos dice que mientras mas dinero en el fondo de pension mayor la expectativa de vida, con su indicador vemos que si la variable fue imputada este efecto es menor, hours nos dice que mientras mas años trabajando mayor sera la expectativa de vida, posiblemente por tener más dinero. La variable edu no fue significativa, la cual era importante en este modelo, por lo que se probara el de efectos aleatorios.

0.4 Ejecute un modelo de efectos aleatorios para estimar la misma relacion anterior. Seleccione las variables independientes a incluir en el modelo final e interprete su significado

```
                        RandomEffects Estimation Summary
================================================================================
Dep. Variable:             expectancy   R-squared:                       0.0846
Estimator:              RandomEffects   R-squared (Between):             0.0406
No. Observations:               26660   R-squared (Within):              0.1301
Date:                Tue, May 20 2025   R-squared (Overall):             0.0846
Time:                        20:53:20   Log-likelihood                -1.734e+05
Cov. Estimator:            Unadjusted
                                        F-statistic:                     98.462
Entities:                       12584   P-value                          0.0000
Avg Obs:                        2.1186   Distribution:               F(28,26631)
Min Obs:                        1.0000
Max Obs:                        5.0000   F-statistic (robust):            87.846
                                         P-value                          0.0000
Time periods:                        5   Distribution:               F(28,26631)
Avg Obs:                        5332.0
Min Obs:                        4438.0
Max Obs:                        7010.0

                                Parameter Estimates
================================================================================
==
                Parameter  Std. Err.     T-stat    P-value    Lower CI    Upper
CI
--------------------------------------------------------------------------------
--
edu               -1.4034     0.2502    -5.6098     0.0000     -1.8938
-0.9131
children          -4.5209     2.0234    -2.2343     0.0255     -8.4868
-0.5550
status_2_0         2.2859     3.2218     0.7095     0.4780     -4.0291
8.6009
```

status_3_0	0.9037	3.7013	0.2441	0.8071	-6.3511	8.1585
status_4_0	3.8872	8.4673	0.4591	0.6462	-12.709	20.484
status_5_0	11.012	2.7212	4.0467	0.0001	5.6781	16.345
lmp_1	34.942	17.078	2.0460	0.0408	1.4680	68.415
lmp_2	37.547	16.998	2.2089	0.0272	4.2304	70.864
nocronica	9.4230	7.8185	1.2052	0.2281	-5.9016	24.748
mental	-10.451	7.5765	-1.3794	0.1678	-25.301	4.3993
nueva_edad	10.161	0.2849	35.665	0.0000	9.6029	10.720
illness_flag	-392.19	30.359	-12.918	0.0000	-451.70	-332.69
illness	-10.976	4.2913	-2.5577	0.0105	-19.387	-2.5647
cronica	28.138	5.6901	4.9450	0.0000	16.985	39.291
cotizando_flag	75.903	16.980	4.4702	0.0000	42.622	109.18
cotizando	-79.296	16.697	-4.7491	0.0000	-112.02	-46.569
assets_flag	8.0840	0.2562	31.557	0.0000	7.5819	8.5861
assets	-5.4417	1.1053	-4.9234	0.0000	-7.6082	-3.2753
sistema	74.673	10.944	6.8232	0.0000	53.222	96.123
sistema_flag	-4.4809	7.6056	-0.5892	0.5558	-19.388	10.427
publicemp	-3.3177	3.1265	-1.0612	0.2886	-9.4458	2.8103
informal	-4.5921	3.5799	-1.2828	0.1996	-11.609	2.4247
hours_flag	-3.7659	0.2731	-13.788	0.0000	-4.3012	-3.2305
hours	3.1855	0.3026	10.528	0.0000	2.5924	3.7786
wage	14.382	2.2546	6.3790	0.0000	9.9629	18.801
exp	5.9782	0.3362	17.780	0.0000	5.3192	6.6373
exp_flag	-5.2365	0.2879	-18.191	0.0000	-5.8007	-4.6723

```
children_flag      2.9303     2.7452     1.0674     0.2858     -2.4505
8.3110
kids              -9.4268     3.8837    -2.4273     0.0152     -17.039
-1.8145
================================================================================
==
```

R. Hay precencia de un r2 menos que el de efectos fijos. En este modelo fue significativo edu, con un coeficiente de -1,4 indica que a mayor niveles de estudio menor expectativa de vida, las variables flag indican en su mayoria que las variables inputadas tienen menores expectativas de vida, menos cotizando y assets; children indica que tener hijos produce menor expectativa de vida, status5 en este modelo fue significativa y nos dice que si es soltero tiene mayor espectativa de vida, podria relacionarse con children, los lmp son significativos e indican que si la persona trabaja tiene mayor espectativa de vida, edad lo mismo que los modelos anteriores, a mayor, mayor expectativa; de manera extraña en este caso al tener una enfermedad cronica aumenta la expectativa de vida en 28 años, Cotizando y assets en este caso son negativas y su indicador positivo, puede que haya sido afectado por los valores imputados. Hours nos dice que a mayor cantidad de trabajo mayor expectativa de vida en 3 años, y su indicador nos dice que los datos imputados tuvieron expectativas de vida menor. Wage y exp en este modelo fueron significativas y producen mayor expecativa.

0.5 Comente los resultados obtenidos en 2, 3 y 4. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investgación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

```
                    Model Comparison
=========================================================
                         Fixed Effects    Random Effects
---------------------------------------------------------
Dep. Variable               expectancy        expectancy
Estimator                     PanelOLS     RandomEffects
No. Observations                 26660             26660
Cov. Est.                   Unadjusted        Unadjusted
R-squared                       0.1964            0.0846
R-Squared (Within)              0.1964            0.1301
R-Squared (Between)            -1.6890            0.0406
R-Squared (Overall)            -0.7629            0.0846
F-statistic                     165.19            98.462
P-value (F-stat)                0.0000            0.0000
=====================     ============   ===============
edu                             0.0036           -1.4034
                              (0.0048)         (-5.6098)
children                       -0.2692           -4.5209
                             (-0.0251)         (-2.2343)
status_2_0                     -1.9678            2.2859
                             (-0.2549)          (0.7095)
status_3_0                      6.0323            0.9037
```

	(0.7290)	(0.2441)
status_4_0	11.808	3.8872
	(0.5062)	(0.4591)
status_5_0	14.468	11.012
	(1.8877)	(4.0467)
lmp_1	-52.371	34.942
	(-1.6111)	(2.0460)
lmp_2	-37.729	37.547
	(-1.1915)	(2.2089)
nocronica	-2.4626	9.4230
	(-0.2178)	(1.2052)
mental	-29.285	-10.451
	(-2.6632)	(-1.3794)
nueva_edad	43.138	10.161
	(24.555)	(35.665)
illness_flag	-486.10	-392.19
	(-6.4084)	(-12.918)
illness	-15.558	-10.976
	(-1.9248)	(-2.5577)
cronica	-13.681	28.138
	(-1.5379)	(4.9450)
cotizando_flag	-82.917	75.903
	(-2.3784)	(4.4702)
cotizando	92.053	-79.296
	(2.6665)	(-4.7491)
assets_flag	18.136	8.0840
	(44.900)	(31.557)
assets	-26.834	-5.4417
	(-9.6810)	(-4.9234)
sistema	-49.202	74.673
	(-1.8407)	(6.8232)
sistema_flag	35.429	-4.4809
	(2.5777)	(-0.5892)
publicemp	4.1140	-3.3177
	(0.5685)	(-1.0612)
informal	7.4617	-4.5921
	(1.0217)	(-1.2828)
hours_flag	-3.7902	-3.7659
	(-10.365)	(-13.788)
hours	4.2675	3.1855
	(9.7771)	(10.528)
wage	-3.6598	14.382
	(-0.7049)	(6.3790)
exp	1.6313	5.9782
	(0.1443)	(17.780)
exp_flag	-12.537	-5.2365
	(-1.1110)	(-18.191)
children_flag	1.3441	2.9303

```
                              (0.1189)          (1.0674)
kids                           -4.2214           -9.4268
                              (-0.5225)         (-2.4273)
======================= ============== =================
Effects                         Entity
-------------------------------------------------------

T-stats reported in parentheses
Hausman chi² = 1536.91, df = 29, p-value = 0.0000
```

R. Las diferencias nacen de las particularidades de los modelos, el pooledOls trata la data ignorando la estructura de panel, el de efectos fijos controla las caracteristicas no observadas constantes en el tiempo controlando heterogeneidad, y el de efectos aleatorios asume que las diferencias son aleatorias y no correlacionadas, con las variable independiente. Las principales diferencias fueron que en el pooledols y efecto aleatorio la variable edu fue significativa, tambien en los modelos las variables fueron significativas en uno y en otro no, como wage que solo fue significativa en efecto aleatorio y hours en esta misma y pooled ols; y mental fue significativa en efectos fijos y pooledOls. Segun el test de Hausman, deberiamos quedarnos con el modelo de efectos fijos, sin embargo en este modelo edu no fue significativa, si bien explica mejor el comportamiento de las otras variables, edu, que era la importante en este analisis fue descartada, por ello yo me quedaria con efectos aleatorios. Las variables que permanecieron significativas fueron assets, hours,cotizando y edad, considerando solo los ultimos 2 modelos.

0.6 Ejecute un modelo de efectos aleatorios correlacionados (CRE) para estimar la misma relacion anterior. Seleccione las variables independientes a incluir en el modelo final e interprete su significado. Es este modelo adecuado, dada la data disponible, para modelar el componente no observado?

Se eliminó illnes_flag por problemas de correlacion

```
                        RandomEffects Estimation Summary
================================================================================
Dep. Variable:             expectancy   R-squared:                        0.3797
Estimator:              RandomEffects   R-squared (Between):              0.4774
No. Observations:               26660   R-squared (Within):               0.1964
Date:                Tue, May 20 2025   R-squared (Overall):              0.3797
Time:                        20:53:22   Log-likelihood                -1.729e+05
Cov. Estimator:                Robust
                                        F-statistic:                      290.77
Entities:                       12584   P-value                           0.0000
Avg Obs:                       2.1186   Distribution:                F(56,26604)
Min Obs:                       1.0000
Max Obs:                       5.0000   F-statistic (robust):             1538.9
                                        P-value                           0.0000
Time periods:                       5   Distribution:                F(56,26604)
Avg Obs:                       5332.0
Min Obs:                       4438.0
Max Obs:                       7010.0
```

Parameter Estimates

	Parameter	Std. Err.	T-stat	P-value	Lower CI	Upper CI
edu	0.0036	0.8729	0.0041	0.9967	-1.7073	1.7145
children	-0.2692	10.995	-0.0245	0.9805	-21.820	21.282
status_2_0	-1.9678	7.7390	-0.2543	0.7993	-17.137	13.201
status_3_0	6.0323	8.1887	0.7367	0.4613	-10.018	22.083
status_4_0	11.808	25.295	0.4668	0.6406	-37.772	61.389
status_5_0	14.468	7.6125	1.9005	0.0574	-0.4530	29.389
lmp_1	-52.371	34.815	-1.5042	0.1325	-120.61	15.869
lmp_2	-37.729	33.414	-1.1291	0.2589	-103.22	27.765
nocronica	-2.4626	13.591	-0.1812	0.8562	-29.102	24.177
mental	-29.285	11.024	-2.6566	0.0079	-50.891	-7.6781
nueva_edad	43.138	2.3484	18.369	0.0000	38.535	47.741
illness	-15.558	7.5495	-2.0608	0.0393	-30.356	-0.7608
cronica	-13.681	9.2197	-1.4838	0.1379	-31.752	4.3905
cotizando_flag	-82.917	37.323	-2.2216	0.0263	-156.07	-9.7632
cotizando	92.053	36.704	2.5080	0.0121	20.112	163.99
assets_flag	18.136	0.5786	31.346	0.0000	17.002	19.270
assets	-26.834	2.8441	-9.4350	0.0000	-32.409	-21.259
sistema	-49.202	33.936	-1.4498	0.1471	-115.72	17.315
sistema_flag	35.429	15.330	2.3111	0.0208	5.3816	65.477
publicemp	4.1140	7.9445	0.5178	0.6046	-11.458	19.686
informal	7.4617	7.6188	0.9794	0.3274	-7.4715	

22.395						
hours_flag	-3.7902	0.6874	-5.5135	0.0000	-5.1376	-2.4427
hours	4.2675	0.7394	5.7713	0.0000	2.8182	5.7169
wage	-3.6598	5.5301	-0.6618	0.5081	-14.499	7.1794
exp	1.6313	18.090	0.0902	0.9282	-33.827	37.089
exp_flag	-12.537	18.159	-0.6904	0.4899	-48.129	23.055
children_flag	1.3441	11.459	0.1173	0.9066	-21.115	23.803
kids	-4.2214	8.0234	-0.5261	0.5988	-19.948	11.505
edu_mean	-0.7475	0.9221	-0.8106	0.4176	-2.5549	1.0600
children_mean	-1.0923	11.432	-0.0955	0.9239	-23.500	21.315
status_2_0_mean	-1.2734	8.3285	-0.1529	0.8785	-17.598	15.051
status_3_0_mean	-11.667	9.0987	-1.2823	0.1997	-29.501	6.1667
status_4_0_mean	-14.596	26.988	-0.5409	0.5886	-67.493	38.301
status_5_0_mean	-10.499	8.0523	-1.3039	0.1923	-26.282	5.2837
lmp_1_mean	21.909	43.181	0.5074	0.6119	-62.728	106.55
lmp_2_mean	16.075	42.411	0.3790	0.7047	-67.054	99.203
nocronica_mean	6.7431	17.043	0.3957	0.6924	-26.661	40.147
mental_mean	13.866	15.076	0.9197	0.3577	-15.684	43.416
nueva_edad_mean	-37.389	2.3564	-15.867	0.0000	-42.007	-32.770
illness_mean	4.8573	8.8823	0.5469	0.5845	-12.552	22.267
cronica_mean	48.976	12.453	3.9330	0.0001	24.568	73.384
cotizando_flag_mean	161.48	43.620	3.7021	0.0002	75.986	246.98
cotizando_mean	-170.18	42.858	-3.9707	0.0001	-254.18	-86.173
assets_flag_mean	-13.493	0.7047	-19.147	0.0000	-14.874	-12.112
assets_mean	20.861	3.3491	6.2289	0.0000	14.297	

```
27.425
sistema_mean            88.884     37.490     2.3709     0.0178      15.401
162.37
sistema_flag_mean      -51.836     20.030    -2.5879     0.0097     -91.096
-12.576
publicemp_mean         -7.1124     8.5015    -0.8366     0.4028     -23.776
9.5510
informal_mean          -15.395     8.6097    -1.7881     0.0738     -32.271
1.4805
hours_flag_mean         0.9226     0.8287     1.1133     0.2656     -0.7017
2.5468
hours_mean             -1.8767     0.8755    -2.1436     0.0321     -3.5927
-0.1607
wage_mean               6.2433     5.9806     1.0439     0.2965     -5.4790
17.966
exp_mean                1.3740     18.111     0.0759     0.9395     -34.124
36.872
exp_flag_mean           10.138     18.178     0.5577     0.5770     -25.492
45.768
children_flag_mean      0.1377     12.138     0.0113     0.9909     -23.652
23.928
kids_mean              -2.7178     9.4398    -0.2879     0.7734     -21.220
15.785
==============================================================================
=======
```

R. Este modelo es el cual hay mejor explicacion de las variables con un R^2 de aproximadamente 38%, en este modelo fue significativo las variables: edad la cual si aumenta, aumenta la expectativa de vida,mental la cual reduce la expectativa de vida, illness la cual reduce expectativa de vida, pero en menor medida que mental,assets la cual disminuyte la expecativa de vida y hours la cual lo aumenta. Además, el modelo permite diferenciar los efectos entre individuos. En este nivel, se observa que un mayor promedio de edad en un grupo se asocia con menor expectativa de vida, mientras que variables como enfermedad mental, enfermedad y activos muestran un efecto positivo, y las horas trabajadas un efecto negativo. Este contraste entre efectos dentro y entre individuos, particularmente en el caso de la edad, puede interpretarse como el reflejo de factores no observados: mientras los individuos mayores podrían esperar vivir más conforme envejecen (por percepción o cuidado personal), los grupos con mayor edad promedio tienden a mostrar una menor expectativa de vida debido a condiciones estructurales o cohortes con peores condiciones. Si bien este modelo presenta la mejor capacidad explicativa y mayor robustez frente a los otros estimados, es importante destacar que la variable edu, que motivó inicialmente el análisis, no resultó ser significativa en la explicación de la expectativa de vida.

0.7 Usando el modelo CRE, prediga la distribucion del componente no observado. Que puede inferir respecto de la heterogeneidad fija en el tiempo y su impacto en la expectativa de vida?

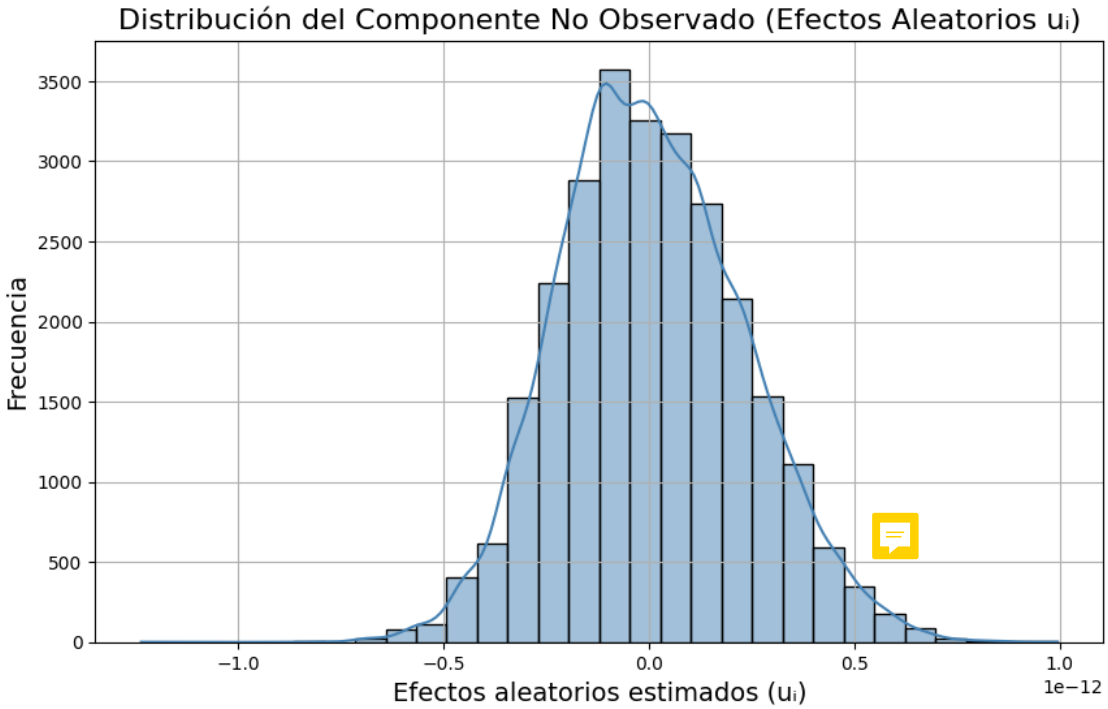

A partir de que la media del componente no observado estimado se encuentra aproximadamente en cero y su forma se asemeja a una distribución acampanada, se puede inferir que los efectos aleatorios siguen una distribución normal, tal como lo asume el modelo. Aunque existe cierta dispersión hacia los extremos, esta es reducida.

Esto indica que la mayor parte de las diferencias individuales no observadas entre personas son pequeñas, por lo que el efecto del componente no observado sobre la variable dependiente (expectativa de vida) es limitado. En consecuencia, el modelo logra explicar una proporción importante de la heterogeneidad entre individuos a través de las variables observadas.

Por tanto, es correcto afirmar que el modelo captura de manera adecuada la influencia de las covariables incluidas en la expectativa de vida de las personas.

0.8 Usando sus respuestas anteriores, que modelo prefiere? que se puede inferir en general respecto del efecto de las variables explicativas sobre la expectativa de vida?

A partir del test de Hausman, se concluyó que el modelo de efectos aleatorios convencional no era adecuado, debido a que las variables explicativas están correlacionadas con el efecto no observado. Por esta razón, opto por utilizar el modelo de efectos aleatorios correlacionados, el cual permite capturar dicha correlación incluyendo los promedios entre individuos de las variables explicativas.

Este enfoque combina las ventajas de los modelos de efectos fijos y aleatorios, proporcionando estimaciones más eficientes y permitiendo interpretar tanto la variación entre como la dentro de los individuos. Aunque la variable edu (que inicialmente motivó el análisis) no resultó ser significativa, el modelo permitió identificar otros factores que influyen significativamente en la expectativa de vida, como la edad, salud mental, afiliación al sistema de cotización y tenencia de activos. Estos resultados contribuyen empíricamente a una mejor comprensión de los determinantes de la expectativa de vida.

En caso de que el objetivo principal hubiese sido únicamente estimar el efecto de los años de educación sobre la expectativa de vida, habría sido más apropiado utilizar un modelo que garantizara la significancia de esa variable, incluso a costa de menor ajuste general. No obstante, dado que el interés era comprender globalmente los factores que inciden en la expectativa de vida, el modelo de efectos aleatorios correlacionados resulta ser el más adecuado.

En general, las variables que mostraron mayor robustez a lo largo de los distintos modelos coincidieron con aquellas que resultaron significativas en el modelo seleccionado. A partir de esto, se puede inferir que, a nivel individual, una persona de mayor edad podría tener una expectativa de vida más alta debido a una mayor valoración del futuro o hábitos más saludables; en cambio, quienes padecen enfermedades tienden a tener una visión más pesimista sobre su futuro, reduciendo así su expectativa de vida. Asimismo, trabajar más horas podría estar asociado a una mayor esperanza en la continuidad del bienestar personal. Sin embargo, cuando se analizan los efectos entre grupos de individuos, estos patrones se invierten: en promedio, los grupos con mayor edad tienden a proyectar una expectativa de vida más baja, probablemente por condiciones estructurales o acumulación de riesgos; las personas con enfermedades podrían, en ese contexto colectivo, estar recibiendo más apoyo o atención, elevando su expectativa; y en el caso de las horas trabajadas, un mayor promedio puede estar asociado a desgaste y menor calidad de vida, reduciendo así la expectativa esperada.

0.9 Bonus track (optativo): Es posible que sus resultados anteriores tengan sesgo dado que quienes esperan vivir mas pueden estar incentivados a adquirir mas educacion. Proponga AL MENOS DOS instrumentos posibles para predecir el nivel de educacion de forma exogena, tal que se pueda corregir el sesgo y entender el efecto causal de las educacion en la expectativa de vida. Realice su estimacion considerando un modelo agrupado (ignorando el tiempo), y el modelo de panel.