TAREA_3_JAVIERA_MONTESINOS

July 5, 2025

1 TAREA 3

Instrucciones

Los resultados de los ejericicios propuestos se deben entregar como un notebook por correo electronico a *juancaros@udec.cl* el dia 6/6 hasta las 21:00. Es importante considerar que el código debe poder ejecutarse en cualquier computadora con la data original del repositorio. Recordar la convencion para el nombre de archivo ademas de incluir en su documento titulos y encabezados por seccion. Utilizar la base de datos junaeb3.csv, el diccionario de datos es el siguiente:

- sexo: sexo del estudiante (1: mujer)
- edad: edad del estudiante (meses)
- imce: indice de masa corporal estandarizado (puntaje z)
- vive_padre: 1 si el padre vive en el hogar (2 indica que tiene mas de un padre)
- vive_madre: 2 si la madre vive en el hogar (2 indica que tiene mas de una madre)
- area: urbana=1, rural=0
- sk1: muestra afecto a padres (1: siempre - 5: nunca)
- sk2: muestra afecto a sus pares (1: siempre - 5: nunca)
- sk3: expresa sus sentimientos (1: siempre - 5: nunca)
- sk4: usa gestos para mostrar sentimientos (1: siempre - 5: nunca)
- sk5: juega con otros (1: siempre - 5: nunca)
- sk6: comparte sus cosas con otros (1: siempre - 5: nunca)
- sk7: es agresivo (1: siempre - 5: nunca)
- sk8: participa en juegos grupales (1: siempre - 5: nunca)
- sk9: hace preguntas a adultos (1: siempre - 5: nunca)
- sk10: tiene interes por libros (1: siempre - 5: nunca)
- sk11: tiene interes por su entorno (1: siempre - 5: nunca)
- sk12: juega a armar y desarmar cosas (1: siempre - 5: nunca)
- sk13: tiene expresiones artisticas (1: siempre - 5: nunca)
- act_fisica: frecuencia actividad fisica (1: nunca - 5: 5 o mas veces a la semana)
- educm: años de escolaridad de la madre
- educp: años de escolaridad del padre
- madre_work: si la madre trabaja (-1: labor domestica, 0: desempleada, 1: empleada)

1.1 Preguntas:

1.1.1 1. Cargue la base de datos y realice los ajustes necesarios para su uso (missing values, recodificar variables, etcetera). Identifique los tipos de datos que se encuentran en la base, realice estadisticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.

R: Primero, se cargaron los datos para su análisis exploratorio. Se generaron distintos gráficos con el fin de examinar la distribución de las variables, identificar posibles valores atípicos (outliers) y visualizar la proporción de valores nulos (NaN) presentes en el conjunto de datos. Posteriormente, se eliminaron los valores nulos y se creó una nueva columna que permitió analizar la distribución por rangos de edad de los niños, la cual fue representada mediante un gráfico de tipo pie chart. Además, se construyó una matriz de correlación para evaluar la relación entre las variables, observándose que ninguna de ellas presentaba una correlación significativa.

	sexo	edad	imce	vive_padre	…	area	educm	educp	madre_work
0	1	85	0.75	1	…	0	11.0	11	-1
1	0	76	0.71	0	…	0	8.0	8	1
2	1	68	0.27	0	…	1	13.0	13	1
3	1	84	2.05	1	…	1	16.0	12	-1
4	0	86	1.05	1	…	1	17.0	15	0
…	…	…	…	…	…	…	…	…	…
31050	0	78	1.63	1	…	1	13.0	13	-1
31051	1	79	2.57	1	…	1	18.0	19	0
31052	0	78	2.12	1	…	1	13.0	9	1
31053	1	78	-0.43	1	…	1	17.0	15	1
31054	0	78	-0.55	0	…	1	18.0	11	1

[31055 rows x 23 columns]

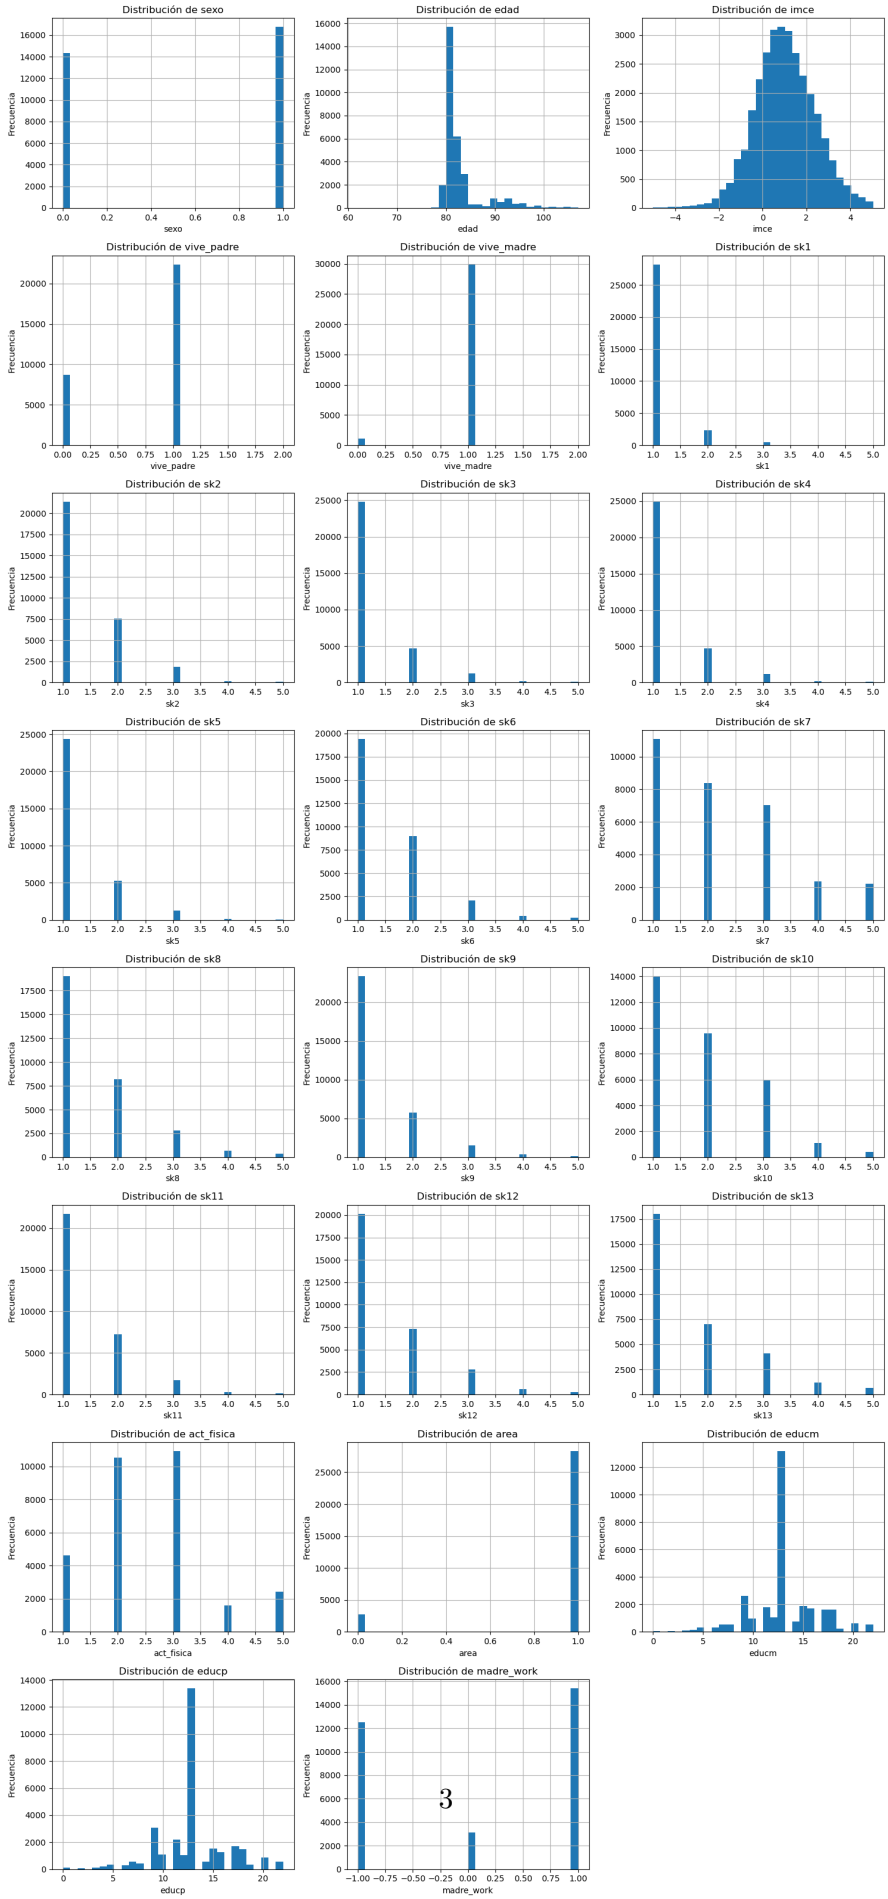
Distribución de sexo
sexo
Distribución de edad
edad
Distribución de imce
imce
Distribución de vive_padre
vive_padre
Distribución de vive_madre
vive_madre
Distribución de sk1
sk1
Distribución de sk2
sk2
Distribución de sk3
sk3
Distribución de sk4
sk4
Distribución de sk5
sk5
Distribución de sk6
sk6
Distribución de sk7
sk7
Distribución de sk8
sk8
Distribución de sk9
sk9
Distribución de sk10
sk10
Distribución de sk11
sk11
Distribución de sk12
sk12
Distribución de sk13
sk13
Distribución de act_fisica
act_fisica
Distribución de area
area
Distribución de educm
educm
Distribución de educp
educp
Distribución de madre_work
madre_work
Frecuencia

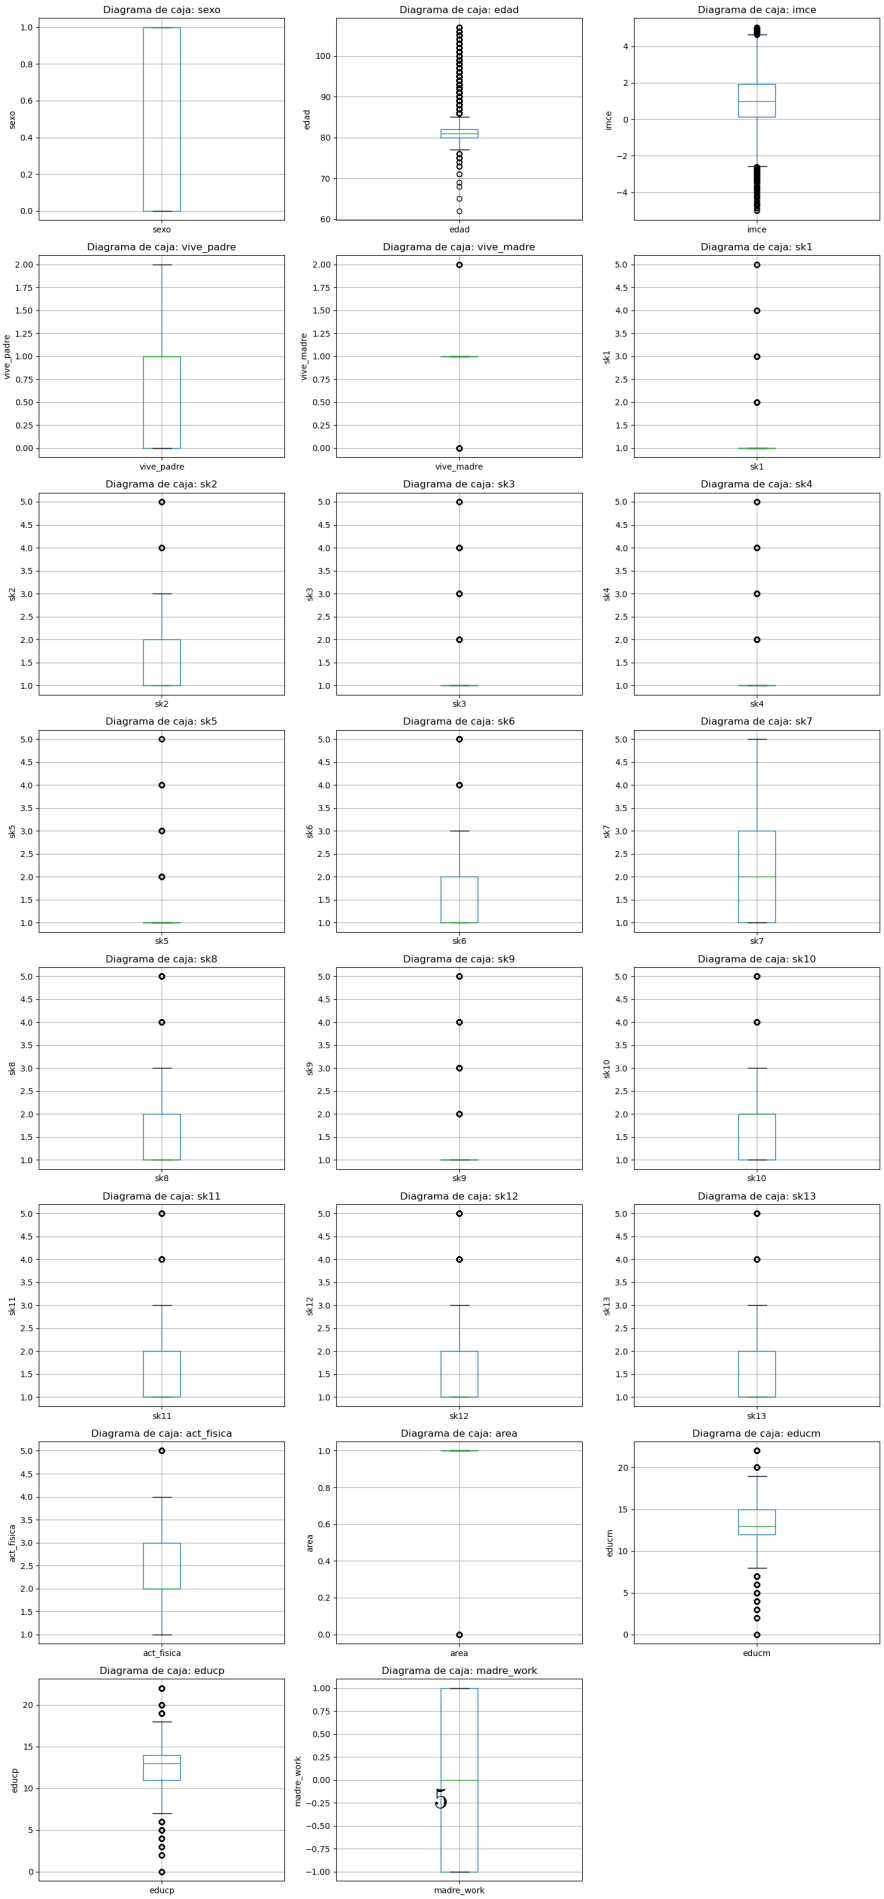
Diagrama de caja: sexo
sexo
Diagrama de caja: edad
edad
Diagrama de caja: imce
imce
Diagrama de caja: vive_padre
vive_padre
Diagrama de caja: vive_madre
vive_madre
Diagrama de caja: sk1
sk1
Diagrama de caja: sk2
sk2
Diagrama de caja: sk3
sk3
Diagrama de caja: sk4
sk4
Diagrama de caja: sk5
sk5
Diagrama de caja: sk6
sk6
Diagrama de caja: sk7
sk7
Diagrama de caja: sk8
sk8
Diagrama de caja: sk9
sk9
Diagrama de caja: sk10
sk10
Diagrama de caja: sk11
sk11
Diagrama de caja: sk12
sk12
Diagrama de caja: sk13
sk13
Diagrama de caja: act_fisica
act_fisica
Diagrama de caja: area
area
Diagrama de caja: educm
educm
Diagrama de caja: educp
educp
Diagrama de caja: madre_work
madre_work

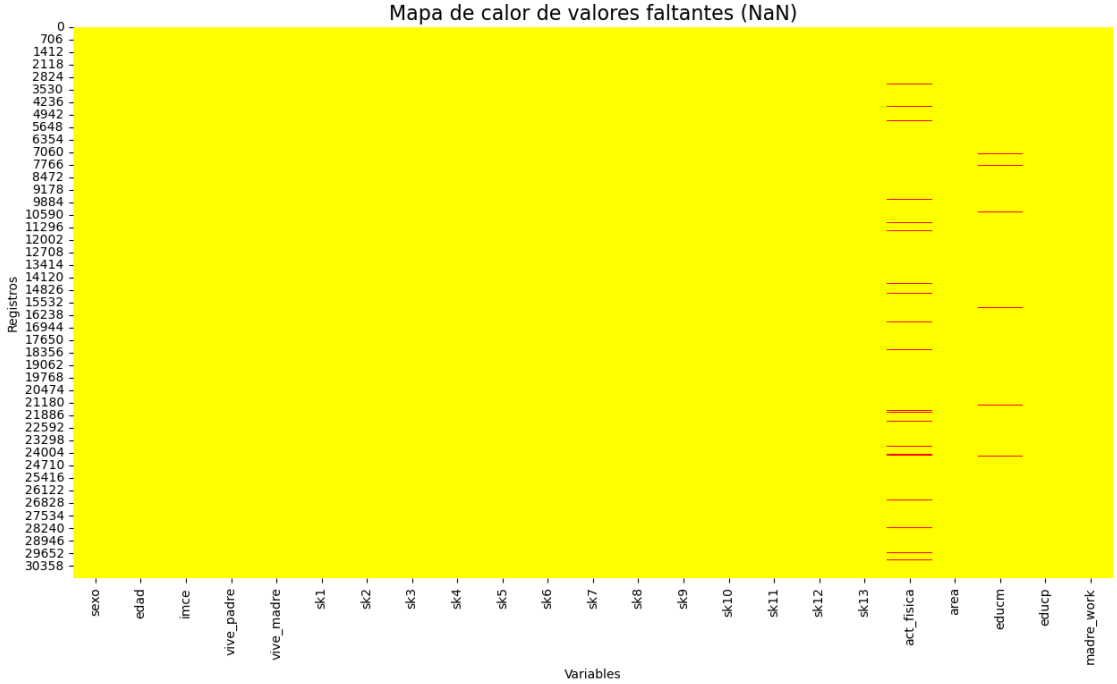


```
C:\Users\HP Envy\AppData\Local\Temp\ipykernel_8856\4004682604.py:1:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-
docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  df['años'] = df['edad'] / 12
```

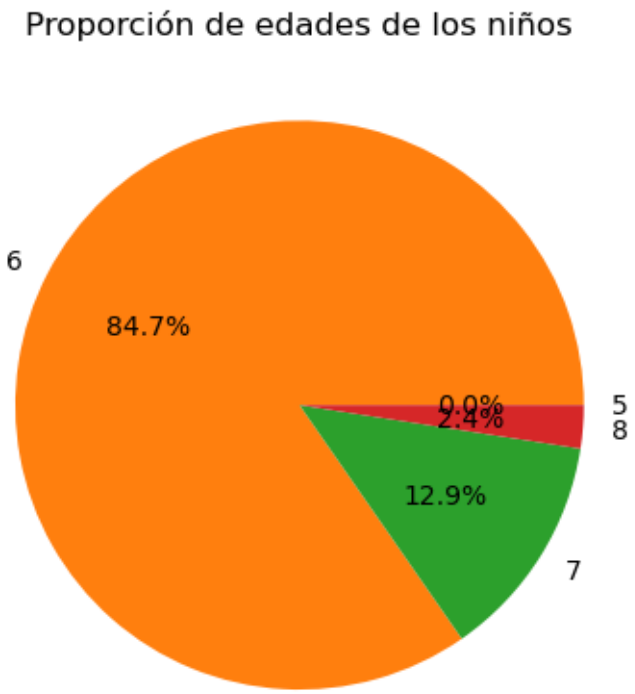


```
<Axes: >
```

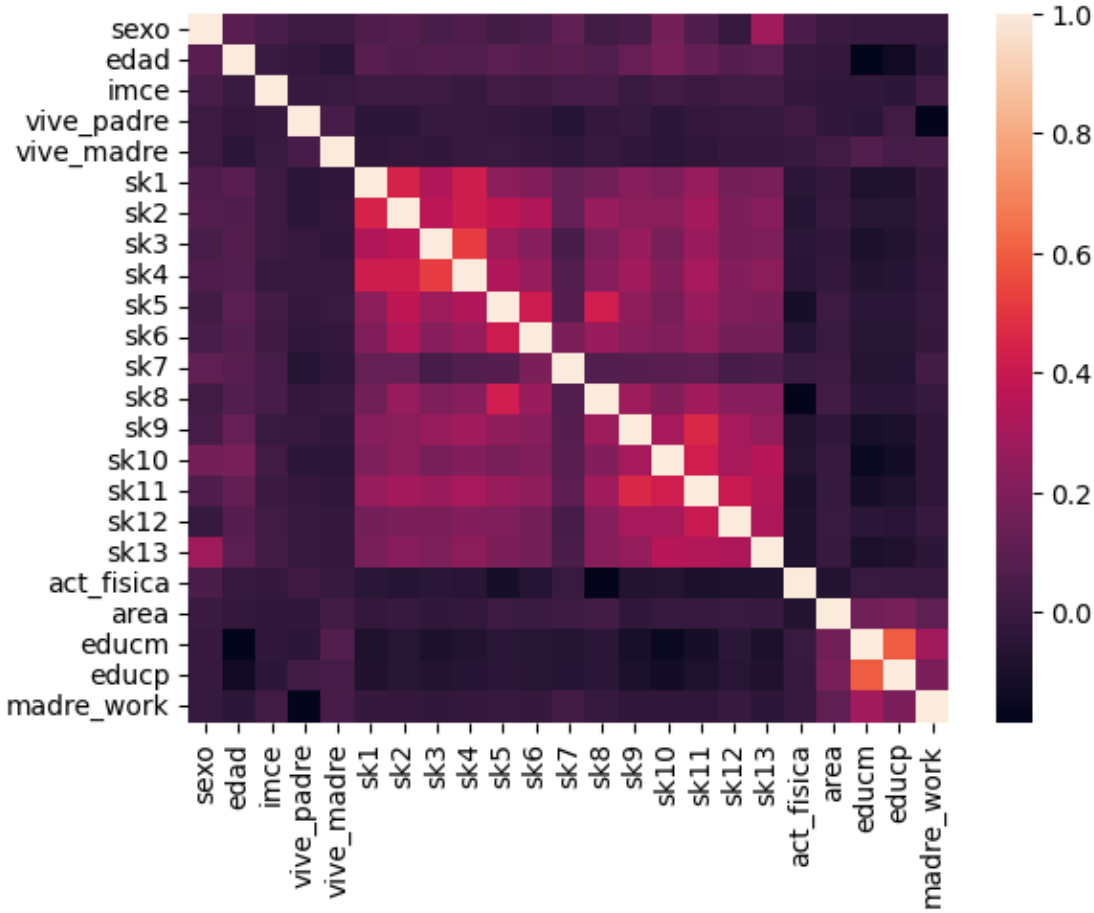

	sexo	edad	imce	vive_padre	…	area	educm	educp	madre_work
1	0	76	0.71	0	…	0	8.0	8	1
3	1	84	2.05	1	…	1	16.0	12	-1
4	0	86	1.05	1	…	1	17.0	15	0
5	0	74	1.39	1	…	0	8.0	8	-1
6	1	91	2.75	1	…	1	20.0	19	1
…	…	…	…	…	…	…	…	…	
31050	0	78	1.63	1	…	1	13.0	13	-1
31051	1	79	2.57	1	…	1	18.0	19	0
31052	0	78	2.12	1	…	1	13.0	9	1
31053	1	78	-0.43	1	…	1	17.0	15	1
31054	0	78	-0.55	0	…	1	18.0	11	1

[29696 rows x 23 columns]

1.1.2 2. A partir de las variables sk1-sk13 realice un EFA. En particular determine el numero optimo de factores y reporte las variables que se asocian a cada factor (usando los factor loadings). Tambien discuta si existen variables que no son informativas. (Hint: para realizar un EFA, todas las variables deben estar representatadas en el mismo sentido logico. Si una carateristica es negativa debe ser invertida en la escala, de tal forma que todas las variables representen aspectos positivos).***

R: Para el análisis, se comenzó generando un DataFrame que incluyera únicamente las variables sk1 a sk13. A continuación, se ajustó un modelo de análisis factorial al conjunto de datos, utilizando rotación varimax para facilitar la interpretación de los factores. Se procedió a graficar los valores propios (eigenvalues) en función del número de factores, con el objetivo de evaluar cuántos factores retener. Siguiendo el criterio de Kaiser que sugiere conservar únicamente los factores con valores propios mayores a 1, se observó que visualmente podrían considerarse hasta cuatro factores. Sin embargo, dado que el cuarto valor se encuentra muy cerca del umbral, se optó por considerar que tres factores serían una mejor elección, tanto estadística como interpretativamente.

Posteriormente, se analizaron las cargas factoriales (loadings), las cuales indican el grado de relación entre cada variable original y los factores extraídos. Para identificar la estructura subyacente, se asignó cada variable al factor con el cual presentaba su mayor carga factorial. A partir de este análisis, se determinó que: - El Factor 1 agrupa las variables sk9, sk10, sk11, sk12 y sk13. - El Factor 2 está compuesto por sk1, sk2, sk3, sk4 y sk8. - El Factor 3 incluye sk5 y sk6.

La variable sk7 mostró cargas factoriales bajas en los tres factores, por lo que no fue asignada a ninguno de ellos, al no presentar una relación significativa con ninguno en particular

	sk1	sk2	…	sk12	sk13
count	29696.000000	29696.000000	…	29696.000000	29696.000000
mean	1.108533	1.386651	…	1.495858	1.687298
std	0.379168	0.643343	…	0.790316	0.979401
min	1.000000	1.000000	…	1.000000	1.000000
25%	1.000000	1.000000	…	1.000000	1.000000
50%	1.000000	1.000000	…	1.000000	1.000000
75%	1.000000	2.000000	…	2.000000	2.000000
max	5.000000	5.000000	…	5.000000	5.000000

[8 rows x 13 columns]

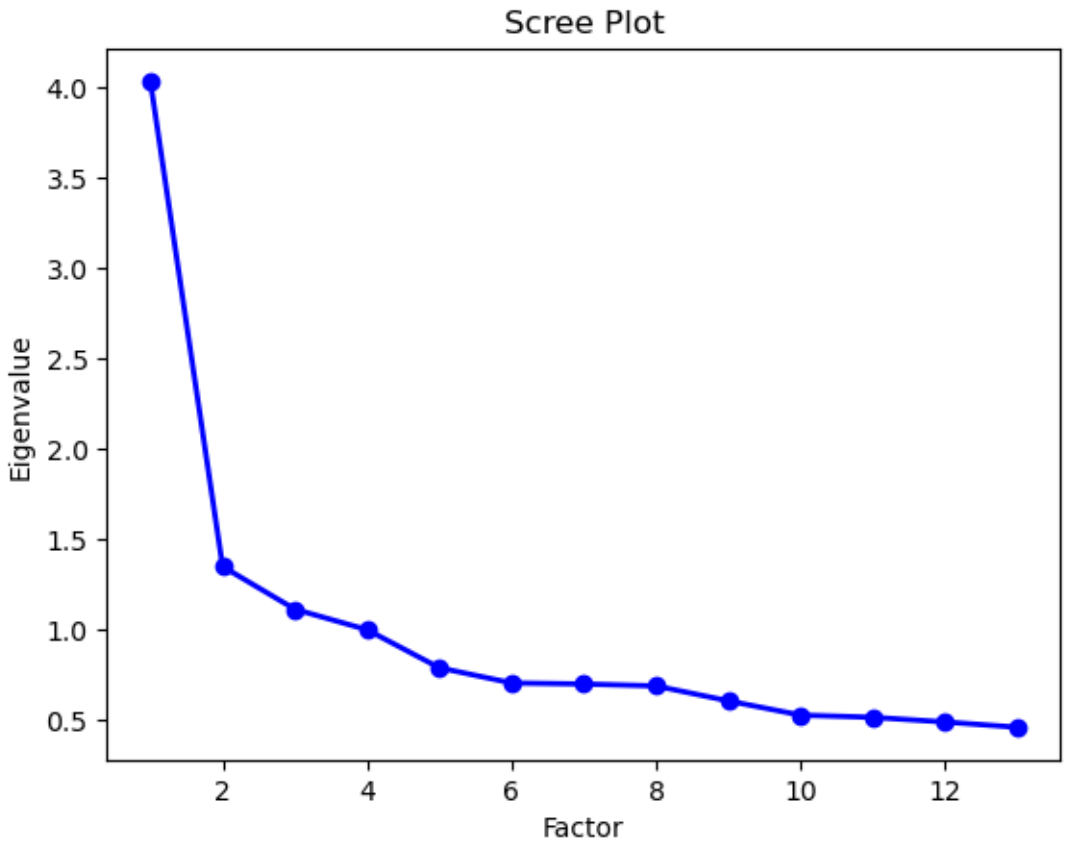


```
array([[0.171221, 0.540217, 0.151458],
       [0.174149, 0.512531, 0.354330],
       [0.179785, 0.587108, 0.161938],
       [0.195805, 0.685256, 0.194526],
       [0.121301, 0.214133, 0.716727],
       [0.162524, 0.203313, 0.486711],
       [0.070301, 0.074530, 0.146613],
       [0.269211, 0.097481, 0.478541],
       [0.495887, 0.205273, 0.201636],
       [0.555989, 0.121166, 0.127875],
       [0.665920, 0.206954, 0.202009],
       [0.524127, 0.109526, 0.141501],
       [0.480548, 0.151480, 0.131725]])

[4.034140 1.350905 1.114858 1.001343 0.791246 0.707033 0.701430 0.690630
 0.608183 0.529379 0.517172 0.491397 0.462285]

      Factor 1  Factor 2  Factor 3
sk1   0.171221  0.540217  0.151458
sk2   0.174149  0.512531  0.354330
```

```
sk3   0.179785  0.587108  0.161938
sk4   0.195805  0.685256  0.194526
sk5   0.121301  0.214133  0.716727
sk6   0.162524  0.203313  0.486711
sk7   0.070301  0.074530  0.146613
sk8   0.269211  0.097481  0.478541
sk9   0.495887  0.205273  0.201636
sk10  0.555989  0.121166  0.127875
sk11  0.665920  0.206954  0.202009
sk12  0.524127  0.109526  0.141501
sk13  0.480548  0.151480  0.131725
```

1.1.3 3. Con los resultados de la Pregunta 2, graficamente indique si existen diferencias significativas en la distribucion de los factores usando las siguientes variables para caracterizar: sexo, area, imce y act_fisica (Hint: usar scatterplot de factores en pares, y ocupar la opcion 'hue' para agregar variables de caracterizacion). Que puede concluir de los resultados?

R: Primero, calculamos los puntajes factoriales utilizando el modelo de análisis factorial previamente ajustado, con el objetivo de poder representarlos gráficamente más adelante. Luego, generamos una nueva columna categórica basada en el valor del IMCE. Para ello, definimos rangos que nos permitieran clasificar a cada individuo según su estado nutricional: Bajo peso extremo(-5 a -3), Bajo peso(-3 a -1), Normal(-1 a 1), Sobrepeso(1 a 3) y Obesidad(3 a 5) Esta variable categórica (cat_imce) se creó a partir de cortes definidos sobre el IMCE, y fue añadida al DataFrame original. Posteriormente, seleccionamos únicamente las variables de caracterización relevantes: sexo, área, el IMCE categorizado y la actividad física, para formar un nuevo DataFrame. Esta información fue luego concatenada con los puntajes factoriales calculados anteriormente.

Finalmente, se generaron gráficos de dispersión emparejados (pairplots) para visualizar todas las combinaciones posibles entre los factores latentes, coloreando según cada variable de caracterización. Sin embargo, tras revisar los gráficos, no se observaron patrones evidentes de agrupación entre los grupos. En la mayoría de los casos, los puntos de diferentes categorías se encontraban dispersos o superpuestos, sin una separación clara que permitiera identificar estructuras o tendencias relevantes entre los factores y las variables de caracterización.

```
       Factor 1  Factor 2  Factor 3  sexo  area   cat_imce  act_fisica
0     -0.711411 -0.311779 -0.401357     0     0     Normal         5.0
1     -0.708078 -0.316767 -0.485394     1     1  Sobrepeso         2.0
2     -0.709744 -0.314273 -0.443376     0     1  Sobrepeso         1.0
3     -0.787695  0.018257 -0.246966     0     0  Sobrepeso         4.0
4      1.759304 -0.071659  0.816447     1     1  Sobrepeso         2.0
…          …        …        …   …   …   …        …          …
29691  0.099888  0.686359  1.106135     0     1  Sobrepeso         2.0
29692  0.942463  0.625515 -0.667683     1     1  Sobrepeso         3.0
29693 -0.178377 -0.408693 -0.589694     0     1  Sobrepeso         3.0
29694 -0.427797 -0.611655  0.973490     1     1     Normal         2.0
29695 -0.835273  0.639916 -0.304029     0     1     Normal         1.0
```

```
[29696 rows x 7 columns]
```

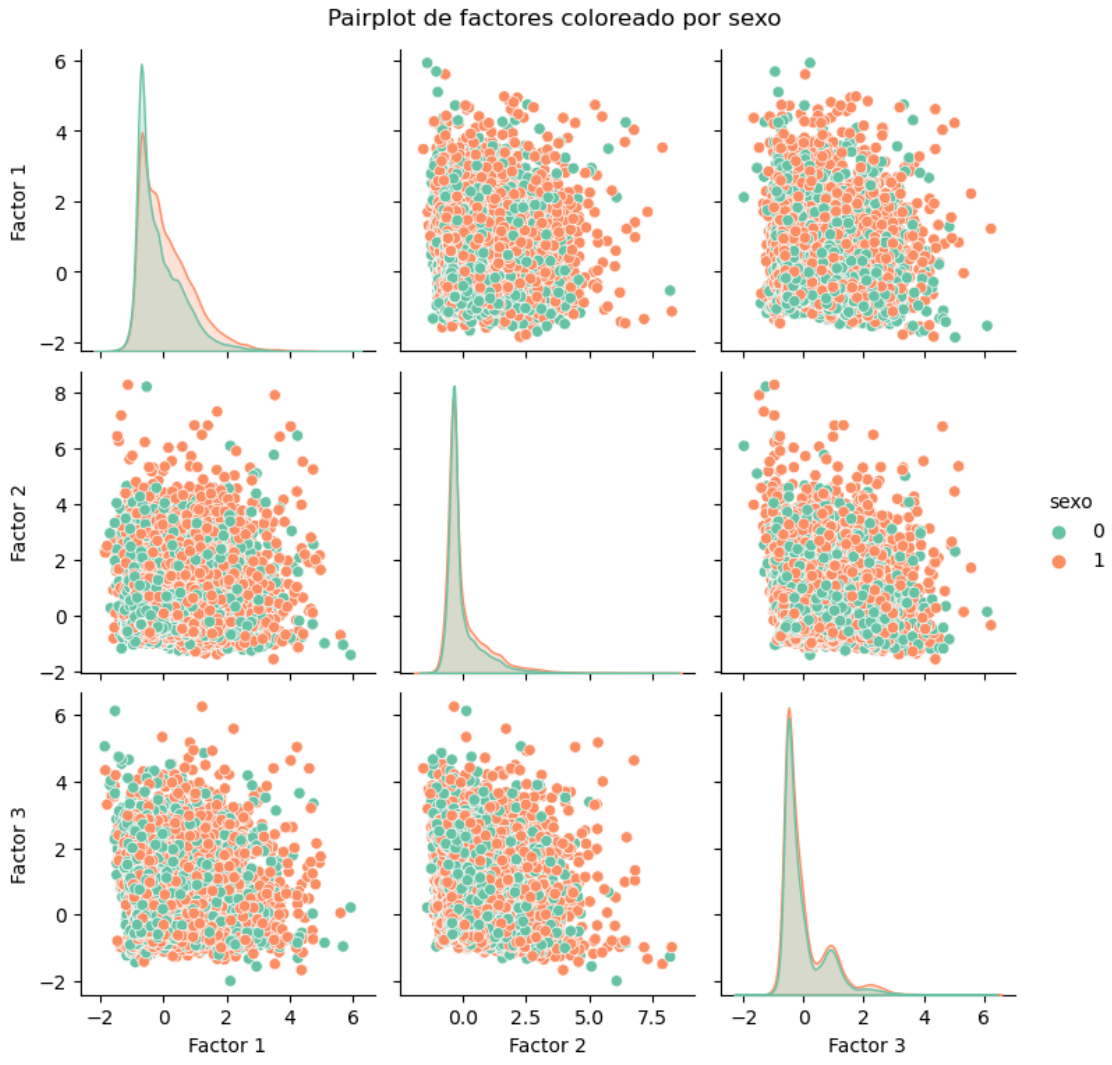

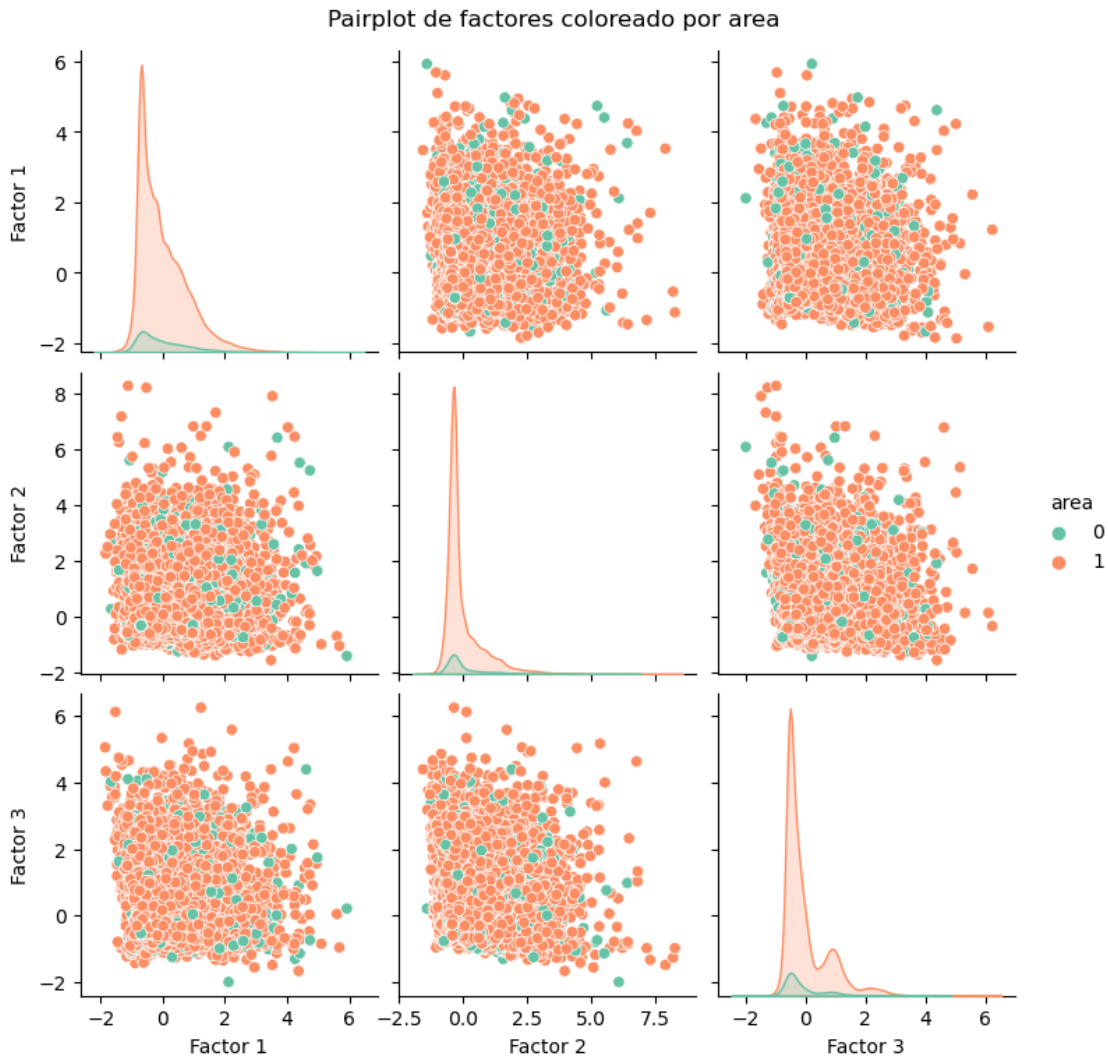
Pairplot de factores coloreado por area
Factor 1
Factor 2
Factor 3
area
0
1

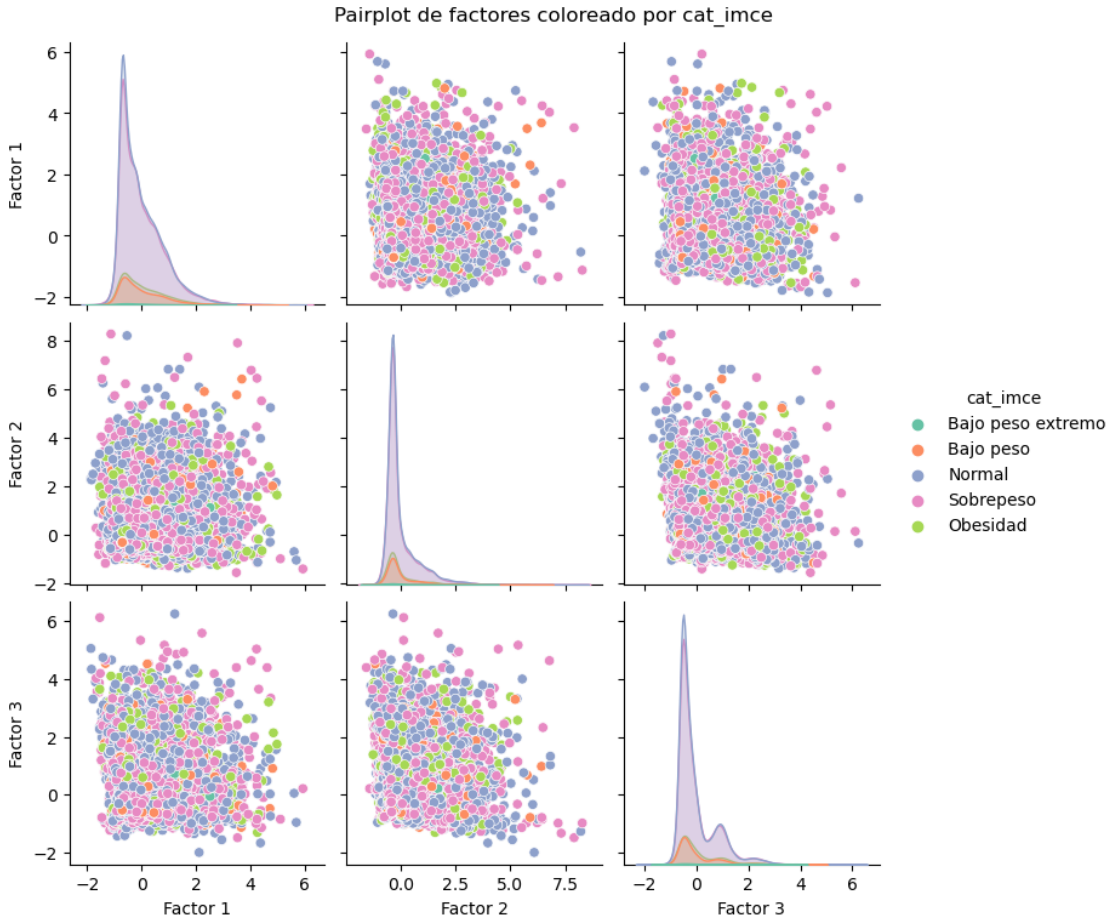
Pairplot de factores coloreado por cat_imce
Factor 1
Factor 2
Factor 3
cat_imce
Bajo peso extremo
Bajo peso
Normal
Sobrepeso
Obesidad

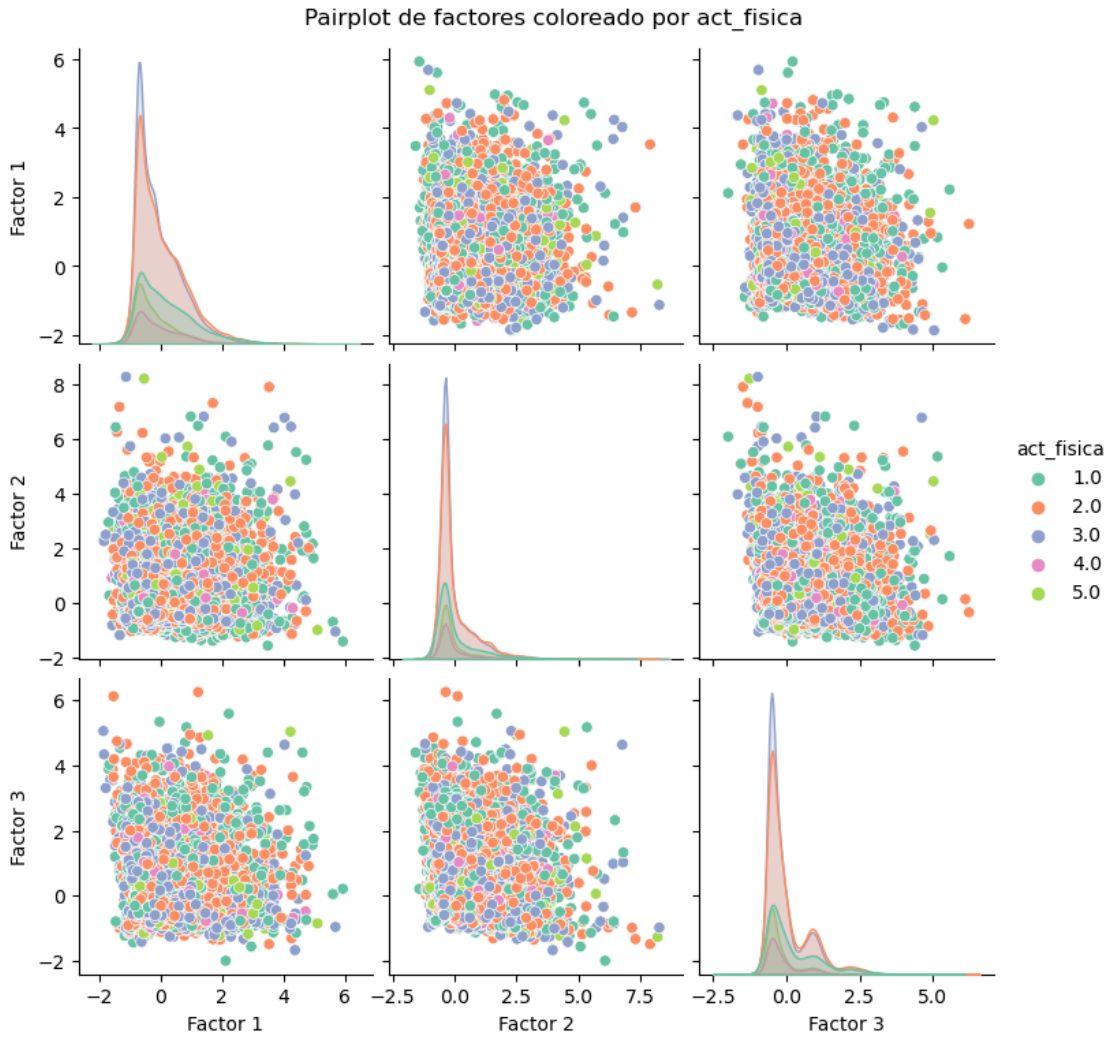

1.1.4 4. Con los resultados obtenidos en la Pregunta 2, proponga un CFA donde cada variable solo se asocia con un factor. Entregue un nombre a cada factor que representa el concepto comun entre las variables incluidas. Reporte la importancia de cada medida (variable) a cada factor e indique la correlacion entre factores (loadings).

R: Con base en los resultados obtenidos en la pregunta 2, proponemos un análisis factorial confirmatorio en el cual cada variable se asocia al factor correspondiente según la estructura mencionada anteriormente. De esta manera, el Factor 1, denominado Interes_Aprendizaje, está compuesto por las variables sk9, sk10, sk11, sk12 y sk13. El Factor 2, llamado Sentimiento, incluye las variables sk1, sk2, sk3, sk4 y sk8. Finalmente, el Factor 3, denominado Interaccion_Cooperativa, agrupa a las variables sk5 y sk6. Primero, definimos el modelo de medición estableciendo los factores latentes, es decir, las variables no observadas que queremos medir. Luego, creamos una instancia del modelo SEM y lo ajustamos utilizando los datos del DataFrame.

Después, inspeccionamos los parámetros estimados del modelo para analizarlos más a fondo y calcu-

lamos las estadísticas de ajuste para evaluar la calidad del modelo. Para determinar la importancia de cada variable en su respectivo factor, utilizamos los valores de estimate obtenidos con la función inspect. Por ejemplo, en el factor 1, las variables que tienen mayor peso son sk10, sk11 y sk13. En el factor 2, destaca especialmente sk2, seguido por sk4, aunque con menor peso. Por último, en el factor 3, la variable sk6 tiene una carga moderada.

En cuanto a la correlación entre factores, al analizar las covarianzas obtenidas con inspect, encontramos que la correlación entre el factor 1 y el factor 2 es de aproximadamente 0.63, lo que indica una relación moderadamente alta: están conectados pero no son iguales. La correlación entre el factor 3 y el factor 1 es más baja, compartiendo algo de varianza pero representando constructos diferenciados. Finalmente, la correlación más alta se da entre el factor 3 y el factor 2, con un valor cercano a 0.7. Aunque es una correlación alta que sugiere cierta redundancia, tiene sentido conceptual mantenerlos separados.

```
Name of objective: MLW
Optimization method: SLSQP
Optimization successful.
Optimization terminated successfully
Objective value: 0.241
Number of iterations: 45
Params: 1.353 1.251 1.099 1.277 1.956 1.637 1.826 1.623 1.098 0.151 0.082 0.153
0.046 0.053 0.062 0.098 0.594 0.199 0.442 0.713 0.238 0.208 0.171 0.159 0.356
0.564 0.278
```

	lval	op	rval	Estimate	Est. Std	Std. Err	z-value	p-value
0	sk9	~	exp	1.000000	0.593288	-	-	-
1	sk10	~	exp	1.353086	0.563486	0.018621	72.664742	0.0
2	sk11	~	exp	1.251091	0.736457	0.014813	84.45829	0.0
3	sk12	~	exp	1.099294	0.540499	0.015583	70.543339	0.0
4	sk13	~	exp	1.276825	0.506584	0.018987	67.245693	0.0
5	sk1	~	sent	1.000000	0.565771	-	-	-
6	sk2	~	sent	1.956309	0.652328	0.024908	78.541572	0.0
7	sk3	~	sent	1.636954	0.610087	0.021694	75.456657	0.0
8	sk4	~	sent	1.825800	0.687630	0.022593	80.81389	0.0
9	sk8	~	sent	1.623222	0.420680	0.028131	57.701712	0.0
10	sk5	~	int	1.000000	0.700083	-	-	-
11	sk6	~	int	1.098032	0.584034	0.01656	66.307071	0.0
12	exp	~~	exp	0.151031	1.000000	0.003067	49.247985	0.0
13	exp	~~	int	0.082486	0.543229	0.001632	50.548558	0.0
14	int	~~	int	0.152660	1.000000	0.003063	49.843375	0.0
15	sent	~~	sent	0.046020	1.000000	0.000974	47.226775	0.0
16	sent	~~	exp	0.053071	0.636586	0.000977	54.329963	0.0
17	sent	~~	int	0.061711	0.736250	0.001039	59.407902	0.0
18	sk1	~~	sk1	0.097748	0.679903	0.000919	106.368517	0.0
19	sk10	~~	sk10	0.594349	0.682484	0.005661	104.993119	0.0
20	sk11	~~	sk11	0.199463	0.457631	0.002533	78.759919	0.0
21	sk12	~~	sk12	0.442232	0.707861	0.004135	106.941155	0.0
22	sk13	~~	sk13	0.713234	0.743373	0.006518	109.426734	0.0

```
23   sk2  ~~   sk2  0.237768  0.574468  0.002444   97.280227     0.0
24   sk3  ~~   sk3  0.207994  0.627794  0.002034   102.27093     0.0
25   sk4  ~~   sk4  0.171035  0.527164  0.001859   92.024824     0.0
26   sk5  ~~   sk5  0.158817  0.509883  0.002499   63.556739     0.0
27   sk6  ~~   sk6  0.355551  0.658904  0.003889   91.433505     0.0
28   sk8  ~~   sk8  0.563912  0.823029   0.00491  114.845412     0.0
29   sk9  ~~   sk9  0.278045  0.648009  0.002724  102.081174     0.0

       DoF  DoF Baseline         chi2  …       AIC         BIC    LogLik
Value   51            66  7149.463982  …  53.51849  277.585216  0.240755

[1 rows x 14 columns]

Empty DataFrame
Columns: [lval, op, rval, Estimate, Est. Std, Std. Err, z-value, p-value]
Index: []
```

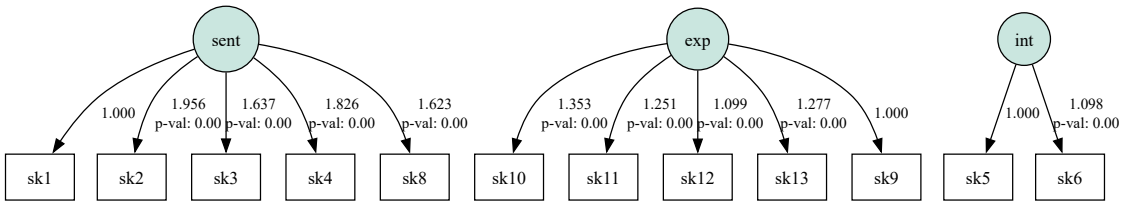

1.1.5 5. Estime un modelo de clases latentes usando imce via StepMix. Determine el numero optimo de clases (clusters) y muestre las diferencias entre clusters graficamente. Que se puede concluir de los resultados?

R: Primero evaluamos modelos de clustering latente con distintos valores de , K (número de clases latentes), con el objetivo de visualizar cómo varía el BIC y así estimar el número óptimo de clusters. Para ello, entrenamos modelos utilizando la técnica de StepMix con diferentes configuraciones.

En una primera instancia, entrenamos dos modelos con 3 clases latentes para comparar el impacto de la estructura de covarianza en el ajuste del modelo. El Modelo 1 utilizó una distribución gaussiana con covarianza diagonal (gaussian_diag), obteniendo un BIC de -771,883 y una entropía de 222, lo cual indica un modelo con buen ajuste y alta certeza en la asignación de clases. El Modelo 2, en cambio, utilizó una distribución gaussiana completa (gaussian), resultando en un BIC de 975,774.18 y una entropía de 7253, lo que sugiere un ajuste considerablemente peor y mayor incertidumbre en la clasificación.

Dado que el modelo con distribución gaussiana diagonal presenta un BIC más bajo y una entropía significativamente menor, se concluye que este ofrece un mejor equilibrio entre ajuste y parsimonia, siendo más adecuado para nuestros datos.

Una vez elegida la especificación adecuada del modelo, entrenamos un nuevo modelo con gaussian_diag utilizando únicamente la variable IMCE. Este modelo clasifica a las observaciones en tres clases latentes, asignando a cada persona el grupo al que pertenece según su IMCE. Esta clasi-

ficación permitirá interpretar posibles perfiles de individuos en base a su índice de masa corporal estandarizado.

Finalmente,al analizar y graficar las distribuciones por clase, podemos observar diferencias claras entre ellas. La clase 0, que agrupa casi el 50% de las observaciones, concentra la mayoría de sus puntajes en un rango entre 0 y 1, lo que indica valores relativamente regulares. Por otro lado, la clase 1 representa principalmente a los individuos con sobrepeso, con puntajes que comienzan alrededor de 1.5 y se extienden hacia valores más altos, abarcando aproximadamente el 41% de los datos. Finalmente, la clase 2, que es la menos representada con cerca del 10% de las observaciones, corresponde a valores bajos del índice, situándose en rangos cercanos a -1 o inferiores.

```
Fitting StepMix…

Initializations (n_init) : 100%|     | 1/1 [00:01<00:00,  1.65s/it,
max_LL=-4.59e+5, max_avg_LL=-15.4]

Fitting StepMix…

Initializations (n_init) : 100%|     | 1/1 [00:03<00:00,  3.35s/it,
max_LL=-4.56e+5, max_avg_LL=-15.4]

Fitting StepMix…

Initializations (n_init) : 100%|     | 1/1 [00:10<00:00, 10.66s/it,
max_LL=-4.55e+5, max_avg_LL=-15.3]

Fitting StepMix…

Initializations (n_init) : 100%|     | 1/1 [00:09<00:00,  9.25s/it,
max_LL=-4.55e+5, max_avg_LL=-15.3]

Fitting StepMix…

Initializations (n_init) : 100%|     | 1/1 [00:09<00:00,  9.21s/it,
max_LL=-4.55e+5, max_avg_LL=-15.3]

Fitting StepMix…

Initializations (n_init) : 100%|     | 1/1 [00:10<00:00, 10.03s/it,
max_LL=-4.55e+5, max_avg_LL=-15.3]

Fitting StepMix…

Initializations (n_init) : 100%|     | 1/1 [00:11<00:00, 11.23s/it,
max_LL=-4.55e+5, max_avg_LL=-15.3]

Fitting StepMix…

Initializations (n_init) : 100%|     | 1/1 [00:11<00:00, 11.25s/it,
max_LL=-4.55e+5, max_avg_LL=-15.3]

 <Axes: >
```

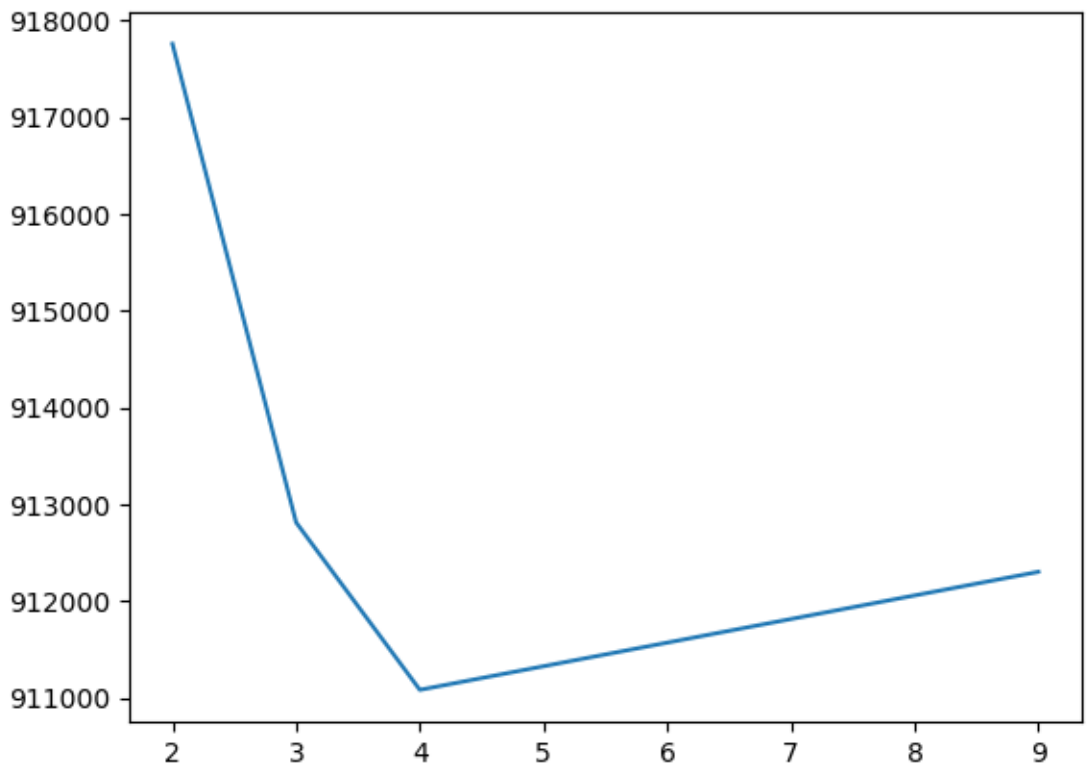


```
Fitting StepMix…

Initializations (n_init) : 100%|      | 1/1 [00:00<00:00,  1.39it/s,
max_LL=-9.9e+4, max_avg_LL=-3.33]

Fitting StepMix…

Initializations (n_init) : 100%|      | 1/1 [00:00<00:00,  1.39it/s,
max_LL=3.96e+4, max_avg_LL=1.33]

Fitting StepMix…

Initializations (n_init) : 100%|      | 1/1 [00:03<00:00,  3.66s/it,
max_LL=4.72e+4, max_avg_LL=1.59]

 <Axes: >
```

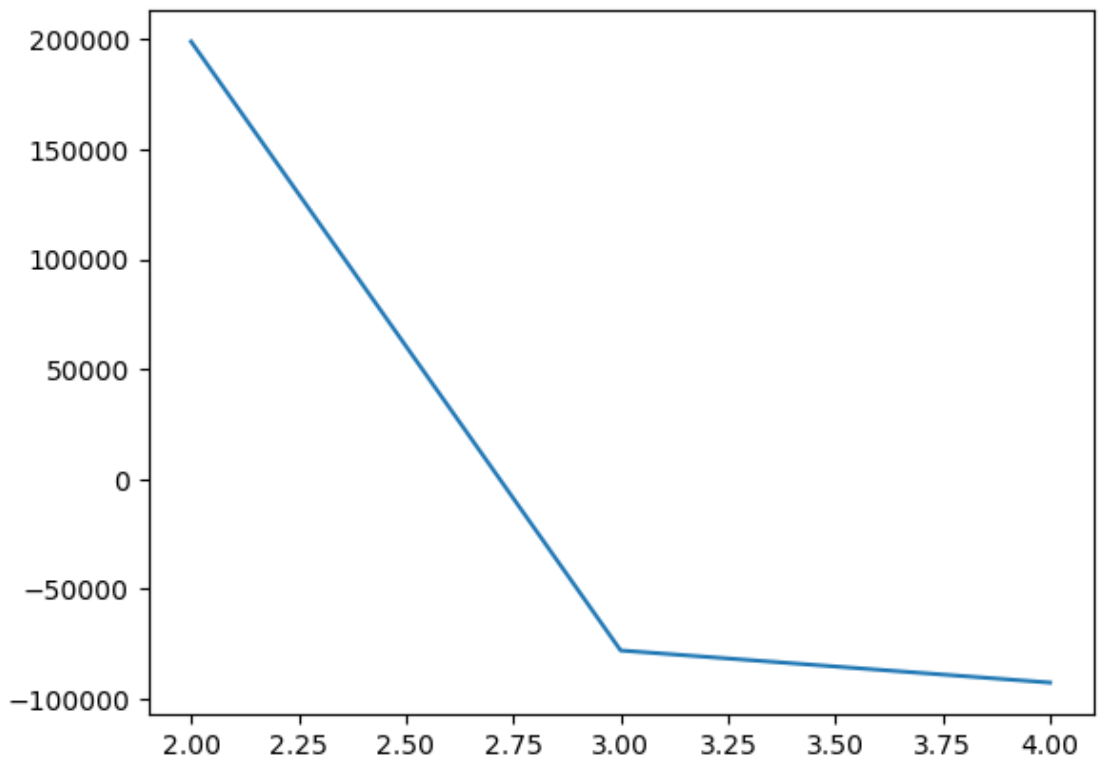


```
Fitting StepMix…

Initializations (n_init) : 100%|      | 1/1 [00:00<00:00,  1.24it/s,
max_LL=3.96e+4, max_avg_LL=1.33]

================================================================================
MODEL REPORT
================================================================================
    ==============================================================================
    Measurement model parameters
    ==============================================================================
          model_name           gaussian_diag
          class_no                         0       1       2
          param       variable
          covariances sk1             0.2802  0.0000  0.0000
                      sk10            1.1124  0.9073  0.7517
                      sk11            0.8816  0.6087  0.2413
                      sk12            0.9519  0.7773  0.4758
                      sk13            1.2959  1.1109  0.7790
                      sk2             0.6157  0.5314  0.1995
                      sk3             0.7369  0.5372  0.0000
                      sk4             0.7700  0.5052  0.0000
                      sk5             0.6282  0.5098  0.1510
                      sk6             0.7606  0.6737  0.4015
```

```
                    sk7             1.4466  1.3335  1.4691
                    sk8             0.8876  0.8220  0.5522
                    sk9             0.8607  0.7063  0.2134
          means     sk1             2.1995  1.0000  1.0000
                    sk10            2.4232  2.0427  1.7057
                    sk11            1.9377  1.6167  1.2301
                    sk12            1.9457  1.7095  1.3688
                    sk13            2.2562  1.9430  1.5312
                    sk2             2.2496  1.6210  1.1988
                    sk3             1.8321  1.8259  1.0000
                    sk4             1.9809  1.7380  1.0000
                    sk5             1.6971  1.4835  1.1383
                    sk6             1.9681  1.7138  1.3470
                    sk7             2.7221  2.2536  2.1556
                    sk8             1.9998  1.7893  1.4158
                    sk9             1.8159  1.5714  1.1840
    ==============================================================================
    Class weights
    ==============================================================================
        Class 1 : 0.09
        Class 2 : 0.22
        Class 3 : 0.69
    ==============================================================================
    Fit for 3 latent classes
    ==============================================================================
    Estimation method             : 1-step
    Number of observations        : 29696
    Number of latent classes      : 3
    Number of estimated parameters: 80
    Log-likelihood (LL)           : 39638.3905
    -2LL                          : -79276.7809
    Average LL                    : 1.3348
    AIC                           : -79116.78
    BIC                           : -78452.88
    CAIC                          : -78372.88
    Sample-Size Adjusted BIC      : -77883.22
    Entropy                       : 222.1888
    Scaled Relative Entropy       : 0.9932


Fitting StepMix…

Initializations (n_init) : 100%|     | 1/1 [00:03<00:00,  3.39s/it,
max_LL=-4.56e+5, max_avg_LL=-15.4]

==================================================================================
MODEL REPORT
==================================================================================
    ==============================================================================
```

```
Measurement model parameters
==============================================================================
      model_name     gaussian_unit
      class_no                   0       1       2
      param variable
      means sk1             1.4683  1.1047  1.0533
            sk10            2.9289  1.6857  1.7032
            sk11            2.2995  1.2880  1.2516
            sk12            2.3841  1.3367  1.3848
            sk13            2.9205  1.4851  1.5299
            sk2             2.0703  1.3635  1.2844
            sk3             1.8231  1.1835  1.1812
            sk4             1.8940  1.1856  1.1621
            sk5             1.8580  1.2371  1.1773
            sk6             2.1545  1.6223  1.3563
            sk7             2.6273  4.1969  1.8345
            sk8             2.3796  1.4844  1.4332
            sk9             2.1188  1.2560  1.2151
==============================================================================
Class weights
==============================================================================
    Class 1 : 0.12
    Class 2 : 0.13
    Class 3 : 0.76
==============================================================================
Fit for 3 latent classes
==============================================================================
Estimation method             : 1-step
Number of observations        : 29696
Number of latent classes      : 3
Number of estimated parameters: 41
Log-likelihood (LL)           : -456049.5156
-2LL                          : 912099.0312
Average LL                    : -15.3573
AIC                           : 912181.03
BIC                           : 912521.28
CAIC                          : 912562.28
Sample-Size Adjusted BIC      : 912813.23
Entropy                       : 7250.2430
Scaled Relative Entropy       : 0.7778

BIC full: 912521.2807102717
BIC diag: -78452.87951453011

Fitting StepMix…

Initializations (n_init) : 100%|      | 1/1 [00:12<00:00, 12.63s/it,
max_LL=-5.13e+4, max_avg_LL=-1.73]

==============================================================================
```

```
MODEL REPORT
==============================================================================
    ==========================================================================
    Measurement model parameters
    ==========================================================================
          model_name           gaussian_diag
          class_no                         0       1       2
          param       variable
          covariances imce            0.9629  1.4229  2.7533
          means       imce            0.5012  1.8813 -0.0576
    ==========================================================================
    Class weights
    ==========================================================================
        Class 1 : 0.49
        Class 2 : 0.41
        Class 3 : 0.10
    ==========================================================================
    Fit for 3 latent classes
    ==========================================================================
    Estimation method             : 1-step
    Number of observations        : 29696
    Number of latent classes      : 3
    Number of estimated parameters: 8
    Log-likelihood (LL)           : -51339.8343
    -2LL                          : 102679.6686
    Average LL                    : -1.7288
    AIC                           : 102695.67
    BIC                           : 102762.06
    CAIC                          : 102770.06
    Sample-Size Adjusted BIC      : 102819.02
    Entropy                       : 22029.9267
    Scaled Relative Entropy       : 0.3247


c:\Users\HP Envy\anaconda3\Lib\site-packages\stepmix\stepmix.py:968:
ConvergenceWarning: Initializations did not converge. Try different init
parameters, or increase max_iter, abs_tol, rel_tol or check for degenerate data.
  warnings.warn(

Fitting StepMix…

Initializations (n_init) : 100%|      | 1/1 [00:11<00:00, 11.68s/it,
max_LL=-5.13e+4, max_avg_LL=-1.73]

==============================================================================
MODEL REPORT
==============================================================================
    ==========================================================================
    Measurement model parameters
    ==========================================================================
```

```
      model_name           gaussian_diag
      class_no                         0       1       2
      param       variable
      covariances imce            0.9629  1.4229  2.7533
      means       imce            0.5012  1.8813 -0.0576
==============================================================================
Class weights
==============================================================================
    Class 1 : 0.49
    Class 2 : 0.41
    Class 3 : 0.10
==============================================================================
Fit for 3 latent classes
==============================================================================
Estimation method             : 1-step
Number of observations        : 29696
Number of latent classes      : 3
Number of estimated parameters: 8
Log-likelihood (LL)           : -51339.8343
-2LL                          : 102679.6686
Average LL                    : -1.7288
AIC                           : 102695.67
BIC                           : 102762.06
CAIC                          : 102770.06
Sample-Size Adjusted BIC      : 102819.02
Entropy                       : 22029.9267
Scaled Relative Entropy       : 0.3247
```

```
c:\Users\HP Envy\anaconda3\Lib\site-packages\stepmix\stepmix.py:968:
ConvergenceWarning: Initializations did not converge. Try different init
parameters, or increase max_iter, abs_tol, rel_tol or check for degenerate data.
  warnings.warn(
C:\Users\HP Envy\AppData\Local\Temp\ipykernel_8856\3506124891.py:7:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-
docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  df1['pred']=model.predict(df3)
```

```
Fitting StepMix…
```

```
Initializations (n_init) : 100%|      | 1/1 [00:11<00:00, 11.57s/it,
max_LL=-5.13e+4, max_avg_LL=-1.73]
c:\Users\HP Envy\anaconda3\Lib\site-packages\stepmix\stepmix.py:968:
ConvergenceWarning: Initializations did not converge. Try different init
parameters, or increase max_iter, abs_tol, rel_tol or check for degenerate data.
```

```
warnings.warn(
```

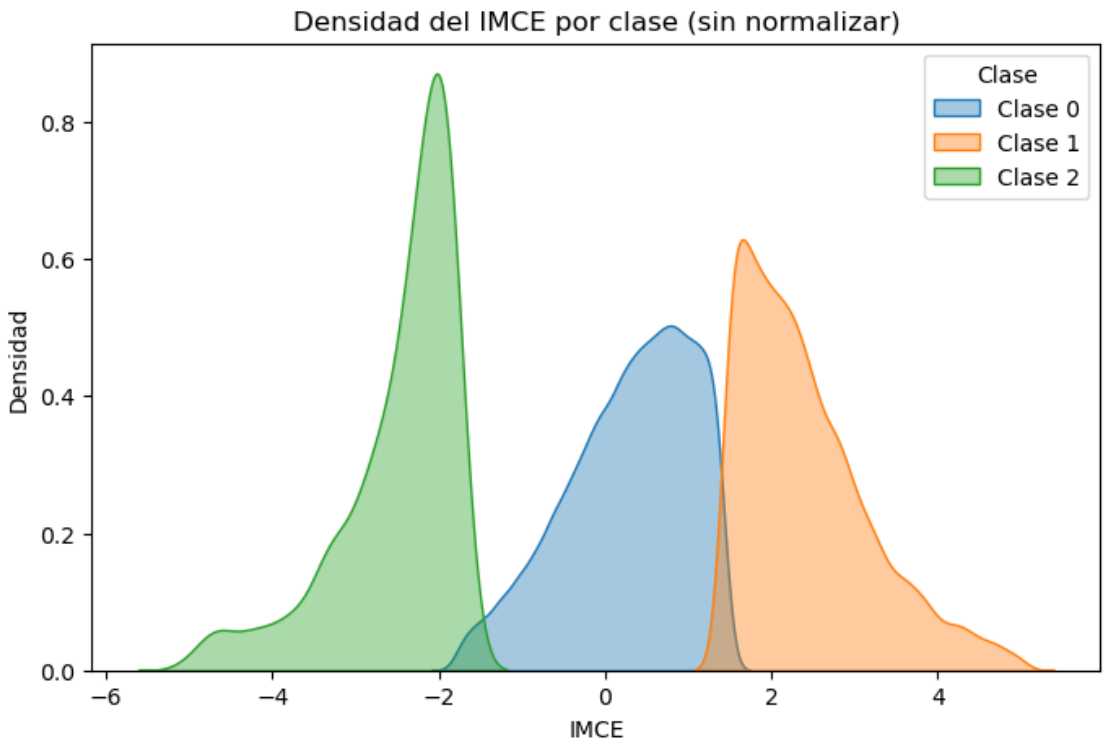

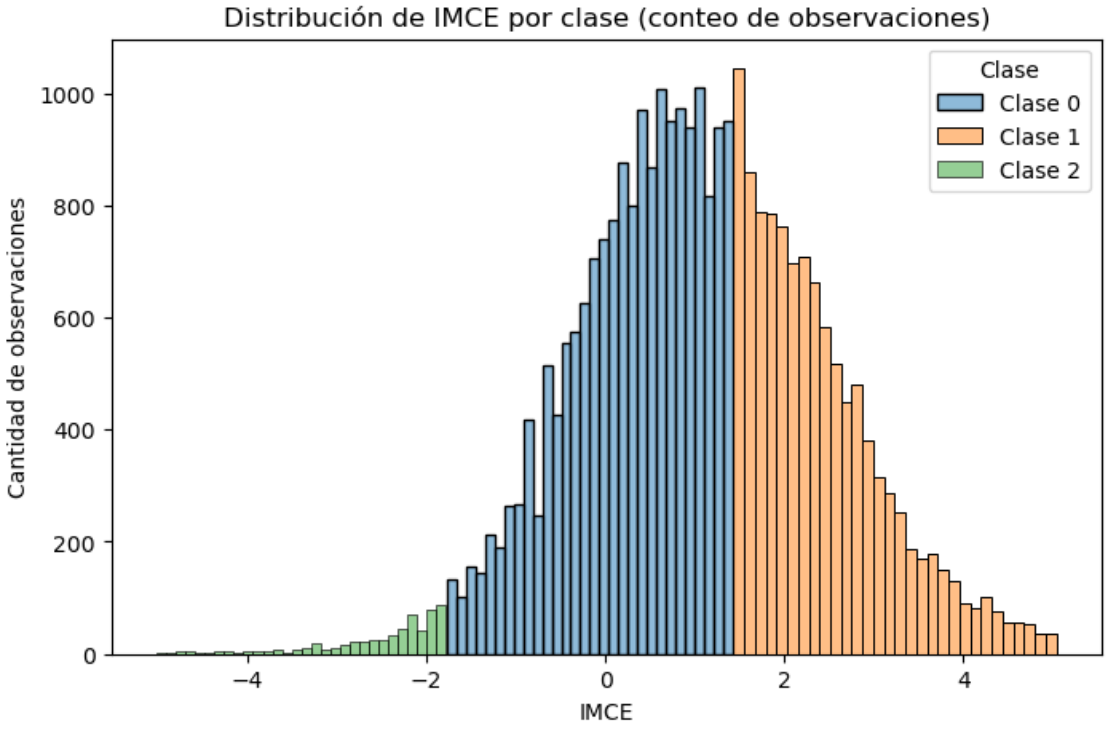

1.1.6 6. Implemente un SEM completo usando la estructura propuesta en la Pregunta 4. En particular, estime un modelo donde los factores latentes explican el imce, junto con otras variables que existen en la base de datos. Ademas utilice otras variables relevantes de la base de datos para su modelo. Las variables a incluir en el modelo final deben tener sustento teorico y el modelo final debe optimizar el ajuste a los datos, en base a los criterios vistos en clase (TLI, CLI, RMSEA). Que puede concluir en base a sus resultados?

R: Después de inspeccionar las variables para explicar el IMCE, determinamos que, además de las clases latentes, las variables de actividad física, sexo, edad, educación de la madre y educación del padre son adecuadas para incluir en el modelo. Esto se concluye porque otras variables, como "vive padre" y "área", fueron descartadas por no ser estadísticamente significativas, mientras que "vive madre" fue excluida debido a que su parámetro estimado fue muy bajo, indicando una contribución mínima al modelo.

Por otro lado, dentro de las variables que explican los factores latentes, observamos que eta1, o interés y aprendizaje, está compuesta por la educación del padre, la educación de la madre y si la madre trabaja, ya que estas variables reflejan habilidades y aspectos del entorno cognitivo y socioeconómico del niño. En cuanto a eta2, o expresión emocional, se consideraron variables como el sexo del niño, la edad, el área donde vive y la frecuencia de actividad física, dado que el sexo y la edad son variables demográficas básicas, el área refleja el contexto geográfico que puede influir en su estilo de vida, y la actividad física está relacionada con comportamientos saludables.

Finalmente, eta3, o interacción cooperativa, está determinada por la presencia de la madre y el padre en el hogar, pues la convivencia con ambos es fundamental para entender el contexto familiar y emocional del niño. Al ajustar el modelo, se obtuvo un CFI de 0.72, indicando un ajuste moderado-bajo; el TLI de 0.67 también sugiere un ajuste bajo, mientras que el RMSEA de 0.074 se encuentra en un rango aceptable pero no óptimo. Estos resultados muestran que, aunque el modelo captura algunos aspectos relevantes, aún presenta limitaciones y podría beneficiarse de ajustes para mejorar su capacidad explicativa.

```
Index(['sexo', 'edad', 'imce', 'vive_padre', 'vive_madre', 'sk1', 'sk2', 'sk3',
       'sk4', 'sk5', 'sk6', 'sk7', 'sk8', 'sk9', 'sk10', 'sk11', 'sk12',
       'sk13', 'act_fisica', 'area', 'educm', 'educp', 'madre_work',
       'imce_class'],
      dtype='object')
```

```
Name of objective: MLW
Optimization method: SLSQP
Optimization successful.
Optimization terminated successfully
Objective value: 1.016
Number of iterations: 79
Params: 1.379 1.237 1.087 1.296 1.917 1.636 1.816 1.561 1.116 0.703 1.046 -0.578
0.251 4.133 -2.759 -2.557 -0.322 -0.001 0.001 0.008 -0.014 -0.007 0.010 0.006
0.029 -0.016 1.113 17.096 10.476 11.134 0.070 0.010 0.062 0.081 0.878 0.243
```

0.097 0.584 0.205 0.446 0.705 0.241 0.205 0.169 0.161 0.353 0.571 0.278

	lval	op	rval	…	Std. Err	z-value	p-value
0	eta1	~	imce	…	-	-	-
1	eta2	~	imce	…	0.014293	49.15458	0.0
2	eta3	~	imce	…	0.018289	57.205448	0.0
3	act_fisica	~	imce	…	0.0296	-19.515774	0.0
4	sexo	~	imce	…	0.013743	18.267365	0.0
5	edad	~	imce	…	0.129414	31.932952	0.0
6	educm	~	imce	…	0.085644	-32.21916	0.0
7	educp	~	imce	…	0.087081	-29.366699	0.0
8	madre_work	~	imce	…	0.023256	-13.841212	0.0
9	eta1	~	educm	…	0.00074	-1.710227	0.087224
10	eta1	~	educp	…	0.000712	1.067045	0.285951
11	eta1	~	madre_work	…	0.002472	3.354625	0.000795
12	eta2	~	sexo	…	0.0028	-5.066189	0.0
13	eta2	~	edad	…	0.000361	-18.365353	0.0
14	eta2	~	area	…	0.004223	2.457695	0.013983
15	eta2	~	act_fisica	…	0.001314	4.626353	0.000004
16	eta3	~	vive_madre	…	0.015427	1.858951	0.063034
17	eta3	~	vive_padre	…	0.005639	-2.79917	0.005123
18	sk9	~	eta1	…	-	-	-
19	sk10	~	eta1	…	0.018664	73.887767	0.0
20	sk11	~	eta1	…	0.014611	84.657108	0.0
21	sk12	~	eta1	…	0.015484	70.224106	0.0
22	sk13	~	eta1	…	0.018996	68.23521	0.0
23	sk1	~	eta2	…	-	-	-
24	sk2	~	eta2	…	0.02438	78.62074	0.0
25	sk3	~	eta2	…	0.02141	76.405147	0.0
26	sk4	~	eta2	…	0.022263	81.577707	0.0
27	sk8	~	eta2	…	0.027584	56.581973	0.0
28	sk5	~	eta3	…	-	-	-
29	sk6	~	eta3	…	0.017258	64.651322	0.0
30	act_fisica	~~	act_fisica	…	0.009295	119.788196	0.0
31	edad	~~	edad	…	0.148869	114.841096	0.0
32	educm	~~	educm	…	0.088323	118.605593	0.0
33	educp	~~	educp	…	0.093371	119.249473	0.0
34	eta1	~~	eta1	…	0.001868	37.689623	0.0
35	eta2	~~	eta2	…	0.000566	18.106658	0.0
36	eta3	~~	eta3	…	0.00224	27.613461	0.0
37	imce	~~	imce	…	0.00229	35.239116	0.0
38	madre_work	~~	madre_work	…	0.007238	121.343198	0.0
39	sexo	~~	sexo	…	0.002027	120.070832	0.0
40	sk1	~~	sk1	…	0.000916	105.57742	0.0
41	sk10	~~	sk10	…	0.005592	104.393257	0.0
42	sk11	~~	sk11	…	0.00251	81.649542	0.0
43	sk12	~~	sk12	…	0.004141	107.709643	0.0

```
44        sk13  ~~        sk13  …  0.006462  109.170189       0.0
45         sk2  ~~         sk2  …  0.002467   97.669571       0.0
46         sk3  ~~         sk3  …  0.002028  101.253999       0.0
47         sk4  ~~         sk4  …  0.001863   90.873903       0.0
48         sk5  ~~         sk5  …  0.002538   63.545565       0.0
49         sk6  ~~         sk6  …  0.003955   89.137086       0.0
50         sk8  ~~         sk8  …  0.004953  115.202782       0.0
51         sk9  ~~         sk9  …  0.002714  102.551819       0.0

[52 rows x 8 columns]

         lval  op        rval   Estimate p-value
3   act_fisica   ~        imce  -0.577659     0.0
4         sexo   ~        imce   0.251047     0.0
5         edad   ~        imce   4.132564     0.0
6        educm   ~        imce  -2.759390     0.0
7        educp   ~        imce  -2.557269     0.0
8   madre_work   ~        imce  -0.321890     0.0
30  act_fisica  ~~  act_fisica   1.113378     0.0
31        edad  ~~        edad  17.096237     0.0
32       educm  ~~       educm  10.475631     0.0
33       educp  ~~       educp  11.134384     0.0
37        imce  ~~        imce   0.080695     0.0
38  madre_work  ~~  madre_work   0.878223     0.0
39        sexo  ~~        sexo   0.243388     0.0

CFI: Value    0.720519
Name: CFI, dtype: float64
- - - - - - - - - - - - -
TLI: Value    0.674702
Name: TLI, dtype: float64
- - - - - - - - - - - - -
RMSEA: Value    0.074268
Name: RMSEA, dtype: float64
```

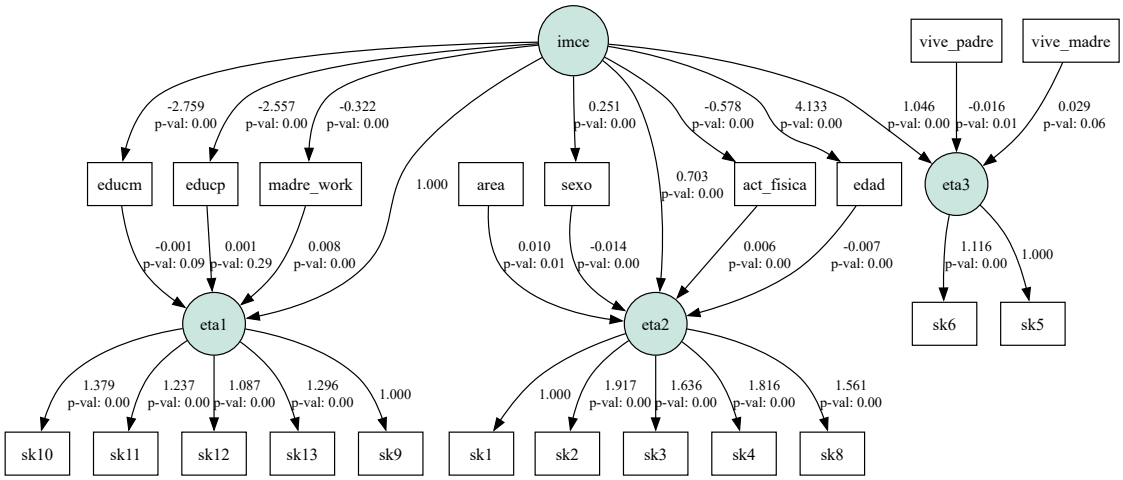

1.1.7 7. Repita el analisis de la Pregunta 6 usando para cada submuestra generada a partir de las clases latentes obtenida en la pregunta 5. Reporte diferencias entre los parametros entre los distintos grupos (si existieran). Hay alguna ganancia de estimar el modelo por grupos versus el modelo general?

R: Se ajustó el modelo SEM para cada subgrupo definido por los clusters de IMCE con el objetivo de evaluar si el ajuste del modelo varía según el estado nutricional: peso normal (cluster 0), sobrepeso (cluster 1) y bajo peso (cluster 2).

Para el grupo con peso normal, el modelo mostró un CFI de 0.718, un TLI de 0.671 y un RMSEA de 0.075, lo que indica un ajuste moderado, aunque no óptimo, manteniéndose dentro de rangos aceptables para modelos complejos. En el grupo de sobrepeso, el ajuste fue ligeramente mejor con un CFI de 0.724, TLI de 0.678 y RMSEA de 0.074, sugiriendo una mejor explicación del modelo para este subgrupo. Por último, el grupo de bajo peso presentó un CFI de 0.728, TLI de 0.683 y RMSEA de 0.072, evidenciando el mejor ajuste relativo entre los tres, aunque sigue siendo un ajuste moderado.

Estos resultados muestran que el modelo tiene un desempeño relativamente estable entre los diferentes grupos, con leves mejoras en los índices de ajuste en los grupos de sobrepeso y bajo peso en comparación con el grupo de peso normal. Sin embargo, en todos los casos, los índices sugieren un ajuste moderado, lo que podría indicar la necesidad de considerar variables adicionales o ajustar la estructura del modelo para mejorar su capacidad explicativa.

En conclusión, el análisis por clusters permite observar cómo la estructura latente se comporta de manera similar pero con pequeñas variaciones en función del estado nutricional, lo que aporta un enfoque más detallado para entender las diferencias en los factores que influyen en el IMCE según el perfil de peso.

```
Resultados para Cluster 0 (Peso normal):
Name of objective: MLW
Optimization method: SLSQP
Optimization successful.
Optimization terminated successfully
Objective value: 1.031
Number of iterations: 80
Params: 1.373 1.234 1.088 1.256 1.907 1.700 1.900 1.556 1.134 0.685 1.022 -0.523
0.246 3.884 -2.726 -2.536 -0.308 -0.001 -0.001 0.006 -0.016 -0.006 0.012 0.005
0.024 -0.013 1.146 16.784 10.467 11.163 0.069 0.010 0.059 0.080 0.881 0.245
0.098 0.569 0.200 0.439 0.697 0.242 0.199 0.167 0.154 0.341 0.547 0.283
Resultados para Cluster 1 (Sobrepeso):
Name of objective: MLW
Optimization method: SLSQP
Optimization successful.
Optimization terminated successfully
Objective value: 1.017
Number of iterations: 79
Params: 1.397 1.250 1.102 1.371 1.909 1.519 1.669 1.521 1.091 0.737 1.086 -0.663
```

```
0.246 4.571 -2.766 -2.573 -0.349 -0.002 0.003 0.013 -0.006 -0.007 0.005 0.009
0.032 -0.023 1.056 17.449 10.514 11.063 0.071 0.011 0.067 0.081 0.872 0.241
0.095 0.608 0.211 0.460 0.717 0.239 0.215 0.171 0.174 0.368 0.605 0.271
Resultados para Cluster 2 (Peso bajo):
Name of objective: MLW
Optimization method: SLSQP
Optimization successful.
Optimization terminated successfully
Objective value: 1.267
Number of iterations: 94
Params: 1.110 1.077 0.834 1.068 2.490 2.241 2.534 2.650 1.045 0.543 1.034 -0.481
0.285 3.399 -2.597 -2.655 -0.235 -0.010 0.010 -0.018 -0.047 -0.007 0.049 -0.004
0.079 0.035 1.143 19.743 9.863 10.964 0.115 0.000 0.051 0.090 0.887 0.232 0.076
0.610 0.235 0.379 0.749 0.245 0.227 0.166 0.156 0.404 0.632 0.244
Grupo 0 (Peso normal) - CFI: Value    0.717764
Name: CFI, dtype: float64 TLI: Value    0.671496
Name: TLI, dtype: float64 RMSEA: Value    0.074688
Name: RMSEA, dtype: float64
Grupo 1 (Sobrepeso) - CFI: Value    0.72365
Name: CFI, dtype: float64 TLI: Value    0.678346
Name: TLI, dtype: float64 RMSEA: Value    0.073943
Name: RMSEA, dtype: float64
Grupo 2 (Peso Bajo) - CFI: Value    0.727678
Name: CFI, dtype: float64 TLI: Value    0.683035
Name: TLI, dtype: float64 RMSEA: Value    0.072166
Name: RMSEA, dtype: float64
```